SAMSUNG

AI Course

Capstone Project Final Report

For students (instructor review required)

ⓒ2023 SAMSUNG. All rights reserved.
Samsung Electronics Corporate Citizenship Office holds the copyright of this document.
This document is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this document other than the curriculum of Samsung Innovation Campus, you must receive written consent from copyright holder.

Together for Tomorrow!
Enabling People
Education for Future Generations

ParaTalent Hub

13/04/2026

NMJ Innovation Team

Ignacio Jiménez Martín
Miguel Martín Rodrigo
Juan S. Flores Olivos

Content

1. Introduction

1.1. Background Information

1.2. Motivation and Objective

1.3. Members and Role Assignments

1.4. Schedule and Milestones

2. Project Execution

2.1. Data Acquisition

2.2. Training Methodology

2.3. Workflow

2.4. System Diagram

3. Results

3.1. Data Preprocessing

3.2. Exploratory Data Analysis (EDA)

3.3. Modeling

3.4. User Interface

3.5. Testing and Improvements

4. Projected Impact

4.1. Accomplishments and Benefits

4.2. Future Improvements

5. Team Member Review and Comment

6. Instructor Review and Comment

7. Annexes

1. Introduction

1.1. Background Information

El Comité Paralímpico Español (CPE) impulsa programas de captación de talento con el objetivo de identificar y desarrollar nuevos deportistas paralímpicos capaces de competir al más alto nivel. Entre estas iniciativas destaca el programa “Nuestra Próxima Estrella”, que actúa como puerta de entrada para personas con discapacidad interesadas en iniciarse o progresar en el deporte paralímpico. Este programa cumple una doble función: por un lado, facilita el acceso al deporte a personas con discapacidad, y por otro, permite detectar perfiles con potencial competitivo. Sin embargo, su eficacia depende directamente de la capacidad del CPE para analizar la información proporcionada por los aspirantes de forma rápida y precisa.

El proceso comienza con la recopilación de datos mediante formularios, donde los candidatos describen su discapacidad, experiencia deportiva y otras características relevantes. Uno de los pasos más críticos dentro de este flujo es la preclasificación funcional, que consiste en determinar, de forma preliminar, en qué categoría paralímpica podría encajar el aspirante y, en consecuencia, qué deportes podrían ajustarse mejor a sus capacidades. Para realizar esta tarea, el personal del CPE interpretan manualmente las descripciones de discapacidad y apoyan sus decisiones en el sistema LEXI Paralympic Classification System, que recoge más de 180 perfiles funcionales representados mediante imágenes y descripciones detalladas. Este proceso requiere un análisis cuidadoso y experto, pero resulta altamente costoso en tiempo, pudiendo implicar varias horas por candidato. Como consecuencia, se genera un cuello de botella que limita el número de aspirantes que pueden ser evaluados y ralentiza la captación de talento.

Por su parte, la información recogida en los formularios presenta alta variabilidad y falta de estructuración, especialmente en los campos de texto libre donde los candidatos describen su discapacidad. Estas características dificultan la aplicación directa de modelos de aprendizaje automático tradicionales, ya que los datos no cumplen los requisitos necesarios en términos de consistencia, estandarización y calidad. Ante este escenario, se planteó la necesidad de desarrollar una solución que abordara de forma directa el principal cuello de botella del proceso: la preclasificación funcional.

De esta manera surge ParaTalent Hub, una herramienta basada en Inteligencia Artificial que permite asistir el proceso de preclasificación de manera eficiente, reduciendo significativamente el tiempo necesario para analizar cada candidato y manteniendo la validación final por parte de los técnicos del CPE. Adicionalmente, como extensión del proyecto y con el objetivo de explorar el potencial de la ciencia de datos en la detección de talento, se desarrolló un modelo predictivo basado en Deep Learning utilizando un dataset externo. Este modelo no forma parte del núcleo operativo de la solución, pero permite demostrar que, bajo condiciones adecuadas de calidad de datos, es posible identificar patrones asociados al rendimiento deportivo y predecir perfiles con potencial de nivel élite.

De este modo, el proyecto combina una solución práctica a un problema real con una visión futura orientada a la incorporación progresiva de modelos predictivos más avanzados, contribuyendo tanto a la eficiencia operativa del CPE como al desarrollo del talento deportivo paralímpico.

1.2. Motivation and Objective

La motivación principal de este proyecto surge de la necesidad de democratizar el acceso al deporte paralímpico y optimizar la detección de talento deportivo mediante el uso de Inteligencia Artificial. Actualmente, el proceso de captación de atletas del CPE depende en gran medida de revisiones manuales, lo que limita tanto la velocidad de análisis como la capacidad de identificar de forma temprana perfiles con alto potencial.

Esta situación genera una doble oportunidad de mejora. Por un lado, la posibilidad de agilizar los procesos de preclasificación funcional, reduciendo la carga operativa del personal del CPE y permitiendo analizar un mayor volumen de candidatos. Y, por otro, la oportunidad de incorporar herramientas de análisis de datos que permitan identificar patrones asociados al rendimiento deportivo, sentando las bases para una detección más objetiva y escalable del talento.

En este contexto, el proyecto ParaTalent Hub se plantea como una solución integral que combina una respuesta inmediata a un problema operativo con una visión futura orientada al análisis predictivo.

Objetivo general
Desarrollar una herramienta basada en Inteligencia Artificial que permita asistir y optimizar el proceso de captación de deportistas del Comité Paralímpico Español, mejorando la eficiencia en la preclasificación funcional y explorando el uso de modelos predictivos para la detección de talento según la discapacidad y potencial de cada persona.

Objetivos específicos

- Automatizar la interpretación de descripciones de discapacidad mediante técnicas de procesamiento de lenguaje natural, utilizando un enfoque basado en recuperación de información (RAG) apoyado en el sistema LEXI Paralympic Classification System.

- Reducir significativamente el tiempo necesario para realizar la preclasificación funcional de los aspirantes, pasando de un proceso manual de varias horas a un sistema asistido en cuestión de minutos.

- Mejorar la consistencia en la sugerencia de categorías funcionales, proporcionando al técnico un conjunto reducido de opciones relevantes (imágenes y descripciones) para su validación final.

- Analizar y evaluar la calidad de los datos proporcionados por el CPE, identificando limitaciones estructurales que condicionan el uso de modelos de aprendizaje automático.

- Desarrollar un modelo predictivo basado en Deep Learning, utilizando datasets externos, con el objetivo de demostrar la viabilidad de identificar perfiles con potencial de nivel élite en condiciones adecuadas de calidad de datos.

- Establecer una arquitectura escalable que permita, en el futuro, integrar datos reales del entorno paralímpico y evolucionar hacia sistemas predictivos adaptados al contexto del CPE.

1.3. Members and Role Assignments

Ignacio Jiménez (Lead Developer & AI Architect): Diseño de la arquitectura RAG (OpenAI + FAISS), desarrollo del Web Scraper, entrenamiento de la Red Neuronal, integración del sistema en Streamlit y conexión con la API de Airtable.

Miguel Martín (Data Scientist & AI Architect): Limpieza y tratamiento de los datos de respuestas de los usuarios de los formularios proporcionados por el CPE, búsqueda y limpieza de datasets para realizar análisis de calidad de los datos y entrenamiento de modelos predictivos. Mejora del rendimiento de red neuronal MLP y de Random Forest.

Juan Flores (Data Scientist & AI Architect): Evaluación de la calidad de los datos proporcionados por el CPE, identificando limitaciones estructurales para su uso en modelos de aprendizaje automático. Diseño y ejecución del proceso de limpieza y homogeneización de variables provenientes de formularios reales. Desarrollo del análisis exploratorio (EDA) para la extracción de insights sobre el perfil de los aspirantes.

1.4. Schedule and Milestones

Hito 1: Extracción y estructuración de la base de datos LEXI (Web Scraping).

Hito 2: Creación del "Cerebro" (Base de datos vectorial y RAG).

Hito 3: Desarrollo del MVP Frontend y conexión con base de datos en la nube.

Hito 4: Entrenamiento y refinamiento de modelos de Machine Learning (MLP y Random Forest) para la detección de talento élite.

2. Project Execution

2.1. Data Acquisition

La adquisición de datos del proyecto se estructuró en torno a tres fuentes principales de información, cada una con un propósito distinto dentro de la solución desarrollada:

I. Los formularios de captación del Comité Paralímpico Español (CPE).
II. La base de conocimiento visual y descriptiva del sistema LEXI.
III. Dataset proporcionado por Korea Sports Promotion Fundation orientado al desarrollo del módulo predictivo de talento.

Datos del CPE

La fuente principal de datos institucionales provino del programa de captación "Nuestra Próxima Estrella" del CPE. Los aspirantes completaban los formularios a través de la propia web del comité, mediante Typeform, y las respuestas eran almacenadas posteriormente en Airtable. Este flujo permitía centralizar la información recogida durante el proceso de captación, incluyendo variables personales, antecedentes deportivos, intereses en distintas disciplinas y, especialmente, una descripción abierta de la discapacidad del candidato.

Desde el punto de vista analítico, se trabajó con varias exportaciones históricas de estos formularios, correspondientes a distintas versiones del cuestionario. Esto implicó enfrentarse a una realidad habitual en entornos operativos: los datasets no compartían una estructura uniforme, presentaban diferencias en el número de variables, en la forma de codificar las respuestas y en el nivel de detalle de determinados campos. Algunas variables aparecían duplicadas o desdobladas entre versiones, mientras que otras habían sido reformuladas o eliminadas con el tiempo.

Por esta razón, la fase de adquisición de datos no se limitó a una simple recopilación de archivos, sino que incluyó una revisión estructural inicial de las distintas fuentes, con el fin de identificar correspondencias entre columnas, inconsistencias semánticas y diferencias de granularidad. Esta etapa fue determinante para establecer posteriormente un proceso de limpieza y homogeneización que permitiera construir un dataset consolidado para análisis descriptivo.

Cabe destacar que, aunque la información del CPE resultó muy valiosa para comprender el perfil de los aspirantes y validar el funcionamiento del sistema de preclasificación, su estructura no era lo suficientemente robusta como para utilizarla directamente en el entrenamiento de modelos predictivos avanzados. En particular, el campo de mayor valor para la herramienta principal fue la variable de descripción libre de la discapacidad, ya que contenía la información semántica necesaria para contrastar cada caso con los perfiles funcionales de LEXI.

Base de datos LEXI

La segunda fuente de información estuvo formada por la base de datos del sistema LEXI (Library of Evidence for Classification in Paralympic Sport), utilizado como referencia para la preclasificación funcional. LEXI proporciona un repositorio visual e interpretativo de perfiles de discapacidad, incluyendo descripciones funcionales e imágenes asociadas a distintas categorías deportivas.

Dado que esta información no se encontraba disponible en un formato directamente utilizable para el sistema propuesto, se desarrolló un proceso de web scraping para extraer automáticamente los recursos necesarios desde la plataforma lexi.global.

El objetivo fue transformar el contenido visual y descriptivo de la plataforma LEXI en una estructura de datos local que sirviera como motor de conocimiento para el sistema. El proceso se diseñó en tres etapas: la extracción recursiva, la consolidación jerárquica y la generación de un índice de compatibilidad cruzada.

La obtención de datos se centralizó en un desarrollo basado en BeautifulSoup y requests. Dada la arquitectura de la web original, no bastaba con un rastreo superficial, por lo que el script scraper_datos_final.py ejecutó una lógica de navegación en tres niveles:

- Nivel de Disciplina: El punto de entrada fue la galería general de deportes. El sistema filtró los nodos HTML con la clase lexi-btn para obtener las rutas de cada disciplina paralímpica, descartando secciones genéricas o no relevantes.

- Nivel de Categoría: Una vez dentro de un deporte (ej. Archery), el motor localizó los enlaces a las diferentes clases funcionales (W1, Open, etc.).

- Nivel de Perfil Médico: En la página final de cada categoría, el scraper extrajo dos bloques de información vital:

    - Contexto General: Identificado bajo la clase lexitext, proporcionando la base normativa de la categoría.

    - Atributos Técnicos de Imagen: Se rastrearon todas las etiquetas <img> con la clase lexiimg. Aquí, la clave fue extraer los metadatos title y alt, que contienen la explicación médica precisa de cada silueta.

Para garantizar la integridad de los recursos, se utilizó urllib.parse.urljoin para resolver las rutas relativas de las imágenes, descargándolas físicamente y renombrándolas de forma normalizada para evitar duplicados o conflictos de nombres.

<u>Organización y Persistencia en lexi_database_FULL.json</u>

Toda la información recolectada se volcó en un diccionario maestro que posteriormente se persistió como un archivo JSON. La estructura de este archivo se diseñó de forma jerárquica para mantener la trazabilidad del dato:

- Key Principal: Nombre del deporte.
- Sub-key: Categoría funcional específica.

Contenido: Un objeto que incluye la descripcion_general y una lista de perfiles_visuales. Cada perfil contiene el nombre del archivo_local y su correspondiente explicacion_medica.

Esta organización permite que el sistema acceda de forma inmediata a toda la anatomía de un deporte sin necesidad de realizar nuevas peticiones externas, reduciendo la latencia de respuesta.

Generación del Índice de Compatibilidad (mapa_deportes.json)

Durante la fase de análisis, detectamos que muchas afectaciones físicas (representadas por una misma imagen/silueta) son comunes a múltiples deportes. Utilizar el JSON jerárquico para buscar deportes compatibles sería computacionalmente ineficiente.

Por ello, se implementó un proceso de inversión de relaciones mediante el script crear_json_deportes.py. Este algoritmo recorre el diccionario maestro y construye un nuevo índice donde la clave es el nombre de la imagen y el valor es una lista de combinaciones "Deporte - Categoría".

Gracias a este mapeo inverso, en cuanto la IA identifica un perfil médico compatible con el relato del atleta, el sistema puede devolver instantáneamente todas las salidas deportivas posibles. Este archivo funciona como la tabla de verdad del sistema, permitiendo que la lógica de negocio sea rápida y escalable.

Dataset externo para el módulo predictivo

Como tercera fuente de datos, se incorporó un dataset externo orientado al desarrollo del módulo de predicción de talento deportivo. En este caso, se utilizó el conjunto de datos Body Performance, obtenido de Korean Sports Promotion Foundation, que contiene registros de rendimiento físico de 13.393 individuos, incluyendo variables relacionadas con fuerza, resistencia, flexibilidad y composición corporal.

La incorporación de esta fuente externa respondió a una necesidad metodológica clara: dado que los datos reales del CPE no presentaban todavía la calidad estructural necesaria para entrenar un modelo predictivo robusto, fue necesario recurrir a un dataset alternativo que sí contuviera variables cuantitativas consistentes y adecuadas para tareas de clasificación supervisada. De este modo, el módulo predictivo desarrollado en el proyecto debe entenderse como una prueba de viabilidad técnica, cuyo objetivo era demostrar que, en presencia de datos estructurados y relevantes, es posible construir modelos capaces de estimar perfiles de alto rendimiento.

En conjunto, en esta fase combinamos fuentes institucionales reales, conocimiento experto externo y datos estructurados de apoyo, permitiendo abordar el proyecto desde una doble perspectiva. Por un lado, se construyó una solución aplicada a una necesidad real del CPE, basada en el procesamiento de texto libre y la recuperación de conocimiento desde LEXI. Por otro, se exploró el potencial del análisis predictivo mediante un dataset externo, como aproximación a futuras líneas de evolución del sistema.

2.2. Training Methodology

A diferencia de los modelos de aprendizaje profundo convencionales, la metodología aplicada para el motor de soporte médico no se basó en un entrenamiento iterativo, sino en la construcción de una infraestructura de Recuperación Aumentada por Generación (RAG). Este proceso se encarga de convertir el conocimiento experto bruto en un índice vectorial consultable, siguiendo estas etapas:

1. Procesamiento del JSON

El punto de partida fue el archivo lexi_database_FULL.json, producto del proceso de scraping. La metodología consistió en vectorizar la información: en lugar de tratar los manuales médicos como bloques masivos, el script cerebro.py descompuso la base de datos en unidades de información independientes. Cada unidad se definió por la tríada: Deporte - Categoría - Descripción Técnica.

2. Ingeniería de Metadatos y Desacoplamiento Semántico

Un paso crítico en la construcción fue cómo estructuramos los objetos Document. Se tomó una decisión de diseño para optimizar la precisión de la futura búsqueda:

- Contenido (Page Content): Se aisló exclusivamente la explicación médica.
- Metadatos (Metadata): Se inyectó el nombre del archivo de imagen (archivo_local) como un atributo oculto.

Lo construimos de esta manera para evitar el ruido semántico. Si hubiéramos incluido los nombres de los archivos o de los deportes dentro del texto a buscar, el sistema podría dar resultados erróneos basados en palabras clave irrelevantes. Al separarlo, garantizamos que el modelo matemático solo compare conceptos médicos, utilizando los metadatos simplemente como un "puntero" para recuperar la imagen correcta una vez hallada la coincidencia.

3. Proyección Vectorial (Embeddings de OpenAI)

Una vez estructurados los documentos, se procedió a su transformación numérica. Se ha seleccionado el modelo text-embedding-ada-002 debido a su capacidad para proyectar conceptos médicos en un espacio de 1536 dimensiones. Esta alta dimensionalidad es fundamental para capturar los matices entre patologías similares (como la diferencia entre Ataxia e Hipertonía), permitiendo que la similitud de coseno sea una métrica de confianza para el triaje inicial.

4. Indexación y Persistencia en FAISS

La fase final de construcción fue la creación del índice de búsqueda mediante FAISS (Facebook AI Similarity Search). En lugar de realizar consultas a una base de datos SQL lenta, el sistema genera una estructura de datos en RAM optimizada para el cálculo de distancias (K-Nearest Neighbors).

Finalmente, se programó la persistencia local del índice en la carpeta faiss_lexi. Esto permite que el sistema no tenga que volver a procesar, traducir o vectorizar la base de conocimiento cada vez que se inicia, convirtiendo a ParaTalent Hub en una herramienta de respuesta inmediata y alta eficiencia computacional.

5. Mapeo de Relaciones Inversas

Como complemento a la base vectorial, se generó el archivo mapa_deportes.json. Este paso de la metodología fue puramente lógico-estructural: se invirtieron las relaciones para que el sistema, una vez identificado un perfil físico, fuera capaz de mapear instantáneamente todas las

disciplinas deportivas asociadas a esa silueta específica, garantizando que ninguna oportunidad deportiva quedara fuera del análisis del inspector.

2.3. Workflow

El flujo de trabajo de ParaTalent Hub se ha diseñado como una canalización de datos de extremo a extremo (End-to-End) que transforma una entrada de lenguaje natural y métricas físicas en una decisión administrativa validada. Este ciclo se divide en cinco etapas:

1. Captación y Sincronización en la Nube (Home.py)

   El proceso se inicia con el usuario (atleta) a través de una interfaz de registro desarrollada en Streamlit.

   - Entrada de Datos: El atleta introduce tres tipos de información: datos biográficos, un relato subjetivo sobre su condición médica y una serie de "Medical Flags" (discapacidad visual, física, intelectual o afectación de extremidades).

   - Persistencia: Al enviar el formulario, el sistema realiza una llamada a la API de Airtable para crear un registro en la tabla maestra. El expediente queda marcado automáticamente con el estado Pendiente, actuando Airtable como un buffer o cola de mensajes para los inspectores del Comité Paralímpico Español (CPE).

2. Activación del Proceso de Triaje (1_Admin.py)

   La fase de análisis comienza cuando el inspector accede al panel de administración.

   - Carga de Recursos: Al iniciar, la aplicación carga en la memoria RAM del servidor el índice vectorial FAISS (generado previamente por cerebro.py) .

   - Selección de Expediente: El inspector selecciona un atleta de la lista de pendientes. En ese instante, el sistema recupera todos los campos asociados al ID del atleta desde la nube.

3. Ejecución del Motor RAG: Búsqueda y Recuperación Semántica

   Una vez seleccionado el atleta, el sistema activa la lógica de Recuperación Aumentada por Generación (RAG) para la clasificación médica:

   - Normalización de Consulta: El relato del atleta se envía a una instancia de LLM para ser traducido y refinado técnicamente al inglés. Esto es esencial para que la consulta sea compatible con el lenguaje experto del corpus LEXI.

   - Cálculo de Distancias (K-NN): La consulta refinada se convierte en un vector numérico. El motor FAISS realiza una búsqueda de los 15 vecinos más cercanos (k=15) mediante el cálculo de similitud de coseno.

   - Filtrado por Reglas estrictas: El sistema analiza los metadatos de los 15 candidatos recuperados. Si el atleta marcó un "Flag" de "No Discapacidad Visual", el sistema

descarta automáticamente cualquier perfil de LEXI que pertenezca a categorías visuales, refinando el contexto antes de que llegue al modelo de lenguaje.

4. Generación de Veredicto y Análisis de Rendimiento

Con el contexto ya depurado, el sistema lanza el proceso de inferencia del LLM (Reranking): Se inyectan las descripciones médicas de los 15 (o menos, tras el filtrado) candidatos en un prompt sistémico. El modelo gpt-4o-mini actúa como clasificador, jerarquizando los 9 perfiles más probables. El Workflow culmina con la intervención del inspector para cerrar el ciclo de decisión:

- Interfaz de Resultados: Los 9 candidatos médicos se presentan de forma paginada (de 3 en 3). El inspector visualiza la silueta técnica de LEXI, la descripción médica original y la lista de deportes compatibles extraída del mapa_deportes.json.
- Actualización de Estado: Una vez que el inspector selecciona el perfil correcto, el sistema realiza una operación UPDATE en Airtable. Se actualiza el estado del atleta a Revisado, se guarda el identificador de la silueta elegida y se registran los deportes sugeridos.
- Cierre de Ciclo: El registro desaparece de la lista de pendientes, garantizando un flujo de trabajo ordenado, trazable y apoyado íntegramente por inteligencia artificial.

2.4. System Diagram

La arquitectura del sistema se ha diseñado siguiendo un modelo de integración modular:

- Capa de Aplicación: Desarrollada íntegramente en Streamlit, elegida por su capacidad para manejar estados de sesión complejos (como la paginación de candidatos).

- Capa de Inteligencia RAG: Basado en LangChain para gestionar el flujo entre la base vectorial FAISS y los modelos de OpenAI.

- Capa de Persistencia: Airtable funciona como nuestro "Backend-as-a-Service", permitiendo que los datos sean accesibles, editables y persistentes en la nube sin necesidad de gestionar servidores propios al igual que la base de datos del CPE.

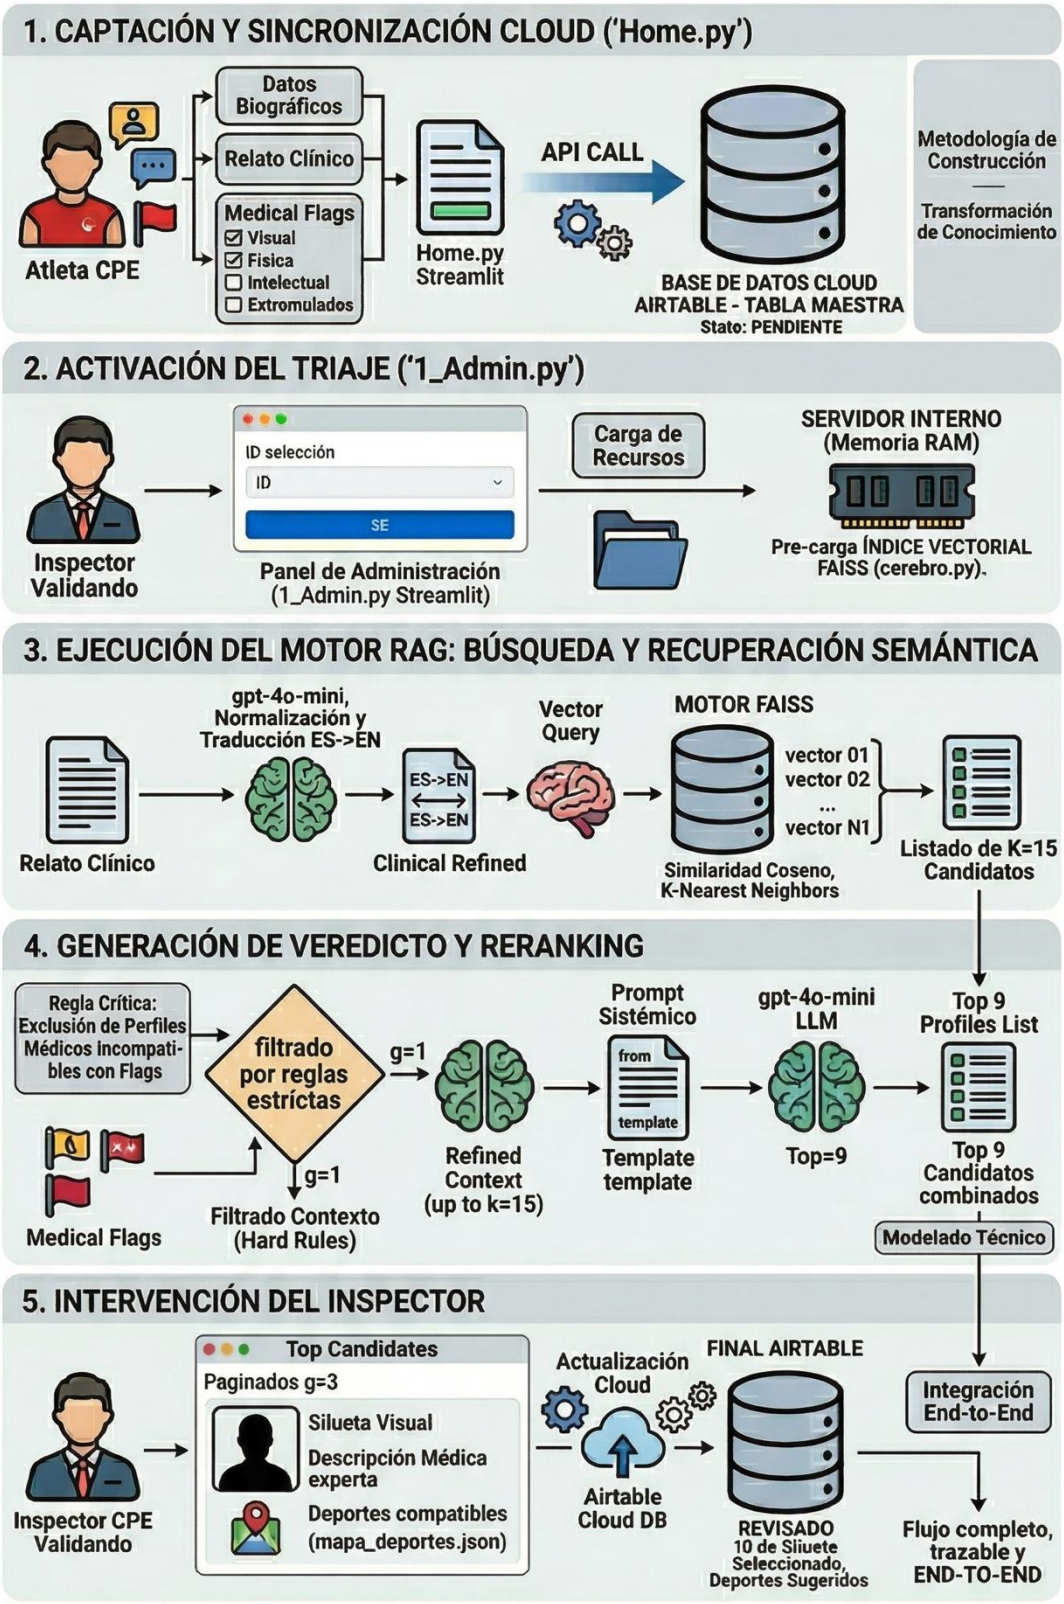
1. CAPTACIÓN Y SINCRONIZACIÓN CLOUD ('Home.py')
Atleta CPE
Datos Biográficos
Relato Clínico
Medical Flags
Visual
Fisica
Intelectual
Extromulados
Home.py Streamlit
API CALL
BASE DE DATOS CLOUD AIRTABLE - TABLA MAESTRA
Stato: PENDIENTE
Metodología de Construcción
Transformación de Conocimiento
2. ACTIVACIÓN DEL TRIAJE ('1_Admin.py')
Inspector Validando
ID selección
ID
SE
Panel de Administración (1_Admin.py Streamlit)
Carga de Recursos
SERVIDOR INTERNO (Memoria RAM)
Pre-carga ÍNDICE VECTORIAL FAISS (cerebro.py).
3. EJECUCIÓN DEL MOTOR RAG: BÚSQUEDA Y RECUPERACIÓN SEMÁNTICA
Relato Clínico
gpt-4o-mini, Normalización y Traducción ES->EN
ES->EN
ES->EN
Clinical Refined
Vector Query
MOTOR FAISS
vector 01
vector 02
...
vector N1
Similaridad Coseno, K-Nearest Neighbors
Listado de K=15 Candidatos
4. GENERACIÓN DE VEREDICTO Y RERANKING
Regla Crítica: Exclusión de Perfiles Médicos incompatibles con Flags
filtrado por reglas estrictas
g=1
g=1
Medical Flags
Filtrado Contexto (Hard Rules)
Refined Context (up to k=15)
Prompt Sistémico
from
template
Template template
gpt-4o-mini LLM
Top=9
Top 9 Profiles List
Top 9 Candidatos combinados
Modelado Técnico
5. INTERVENCIÓN DEL INSPECTOR
Inspector CPE Validando
Top Candidates
Paginados g=3
Silueta Visual
Descripción Médica experta
Deportes compatibles (mapa_deportes.json)
Actualización Cloud
Airtable Cloud DB
FINAL AIRTABLE
REVISADO
10 de Sliuete Seleccionado, Deportes Sugeridos
Integración End-to-End
Flujo completo, trazable y END-TO-END

3. Results

3.1. Data Preprocessing

Datos del CPE

La fase de preprocesamiento de datos fue un paso crítico dentro del proyecto, debido a la heterogeneidad estructural de las distintas fuentes provenientes de los formularios del CPE. Los datos originales presentaban inconsistencias en formato, duplicidades, variables redundantes y una elevada variabilidad semántica, lo que hacía necesaria una transformación profunda antes de cualquier análisis.

Para abordar este problema, se diseñó un pipeline de limpieza y normalización compuesto por varios scripts independientes, documentados en los anexos del presente informe.

Depuración y validación de registros

En una primera etapa, se aplicaron procesos de filtrado para eliminar registros no válidos, tales como respuestas de prueba, nombres ficticios o entradas incompletas. Para ello, se implementaron reglas basadas en expresiones regulares para validar la estructura de los nombres y detectar patrones asociados a datos no reales.

Asimismo, se eliminaron registros sin información de contacto y se llevó a cabo un proceso de eliminación de duplicados, utilizando como criterios combinados el nombre completo y los datos de contacto disponibles (correo electrónico y teléfono). Este proceso permitió reducir el ruido del dataset y garantizar una base de datos más representativa.

Reducción de dimensionalidad y selección de variables

Dado que los formularios incluían un gran número de variables no relevantes para el análisis (como consentimientos legales, metadatos del formulario o información administrativa), se procedió a eliminar estas columnas.
Esta reducción de dimensionalidad permitió centrar el análisis en variables de interés, como:

- tipo de discapacidad
- descripción de la discapacidad
- interés en deportes
- experiencia deportiva previa
- variables relacionadas con la clasificación

Codificación y transformación de variables

Con el objetivo de facilitar el análisis cuantitativo, se aplicaron diversas técnicas de transformación sobre variables categóricas y multirrespuesta.

Entre las principales operaciones realizadas destacan:

- **Binarización de variables multiclase**, como tipos de discapacidad o deportes de interés, convirtiendo cada categoría en una variable independiente (one-hot encoding simplificado).
- **Codificación ordinal** en variables como nivel de práctica deportiva o clasificación previa, asignando valores numéricos que reflejan una jerarquía implícita.

- **Transformación de variables de texto estructurado** en representaciones numéricas consistentes.

Estas transformaciones permitieron convertir un dataset originalmente no estructurado en una base de datos parcialmente apta para análisis estadístico.

Ingeniería de variables (Feature Engineering)

Adicionalmente, se generaron nuevas variables derivadas con el objetivo de enriquecer el dataset y facilitar su interpretación.

Entre las variables creadas se incluyen:
- Indicadores binarios de afectación en miembros superiores e inferiores.
- Número estimado de extremidades afectadas.
- Variable de edad, calculada a partir de la fecha de nacimiento.

Estas variables permitieron capturar información funcional relevante que no estaba explícitamente estructurada en los datos originales.

Homogeneización y fusión de datasets

Uno de los principales retos del preprocesamiento fue la existencia de múltiples versiones del formulario con estructuras distintas. Para resolver este problema, se desarrolló un proceso de homogeneización de esquemas, en el que se unificaron nombres de columnas, tipos de datos y codificaciones entre datasets.

En este proceso se llevaron a cabo las siguientes acciones:
- Alineación de variables comunes entre datasets.
- Creación de columnas faltantes para garantizar consistencia estructural.
- Conversión de tipos de datos a formatos homogéneos.
- Reordenación de columnas para construir un esquema único.

Finalmente, los distintos datasets fueron combinados en un único conjunto consolidado, listo para su análisis exploratorio.

Como resultado de este proceso, se obtuvo un dataset unificado con una estructura consistente y un conjunto de variables depuradas y transformadas, adecuado para análisis descriptivo y exploración de patrones. No obstante, a pesar del esfuerzo de limpieza y homogeneización, el dataset mantenía ciertas limitaciones inherentes a su origen, especialmente en lo relativo a la variabilidad del texto libre y la falta de estandarización en algunas variables clave. Estas limitaciones fueron determinantes en la elección de las técnicas de modelado utilizadas posteriormente.

Dataset externo

Se comprueba que no hay ningún valor faltante en los datos, al igual que se buscan valores duplicados y, en el caso de que los haya, se eliminan.

Así mismo, también se obtienen nuevas columnas partiendo de las que tenemos para intentar mejorar el rendimiento de los modelos. Una que relacione el peso y la altura llamada ‘bmi’ y otra que relaciona la fuerza de agarre y el peso llamada’ relative_grip’.

En la columna de género se modifica la tipología de datos para pasarlos de tipo “object” a tipo “int”.

3.2. Exploratory Data Analysis (EDA)

El análisis exploratorio de datos (EDA) se llevó a cabo con un doble objetivo. Por un lado, comprender la estructura, calidad y características del dataset proporcionado por el CPE, orientado al proceso de captación de deportistas. Por otro, analizar un dataset externo de rendimiento físico con el fin de evaluar su idoneidad para el desarrollo de modelos predictivos de detección de talento.

Esta doble aproximación permitió diferenciar claramente entre un entorno de datos reales, con limitaciones estructurales, y un entorno de datos controlados, más adecuado para el entrenamiento de modelos de aprendizaje supervisado.

Análisis del dataset del CPE
En este análisis pudimos identificar tanto las limitaciones del dataset como las oportunidades para el desarrollo de soluciones basadas en inteligencia artificial.

Figura 1.
Distribución de tipos de discapacidad en aspirantes

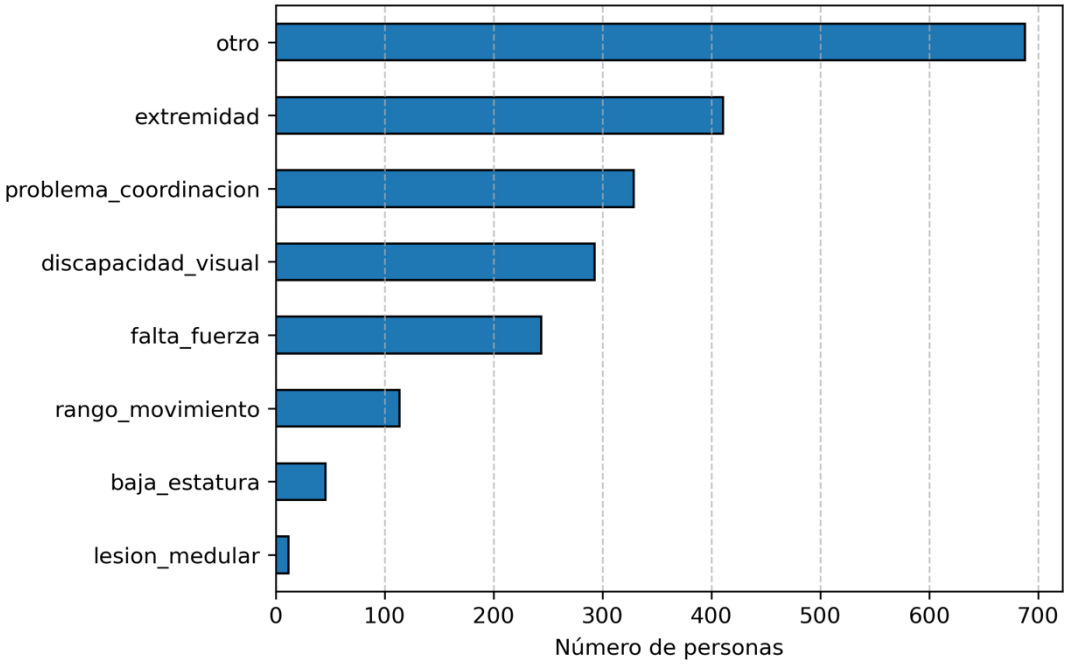

En primer lugar, la Figura 1 presenta la distribución de los diferentes tipos de discapacidad registrados en el dataset. Se identifica una fuerte concentración en la categoría “otro”, lo que indica una falta de estructuración en la recogida de información, así como una posible ambigüedad en las descripciones proporcionadas por los aspirantes. Asimismo, se observa un predominio de discapacidades relacionadas con extremidades y problemas de coordinación, frente a otras menos representadas como lesión medular o baja estatura.

Figura 2.
Distribución de edad de los aspirantes al programa

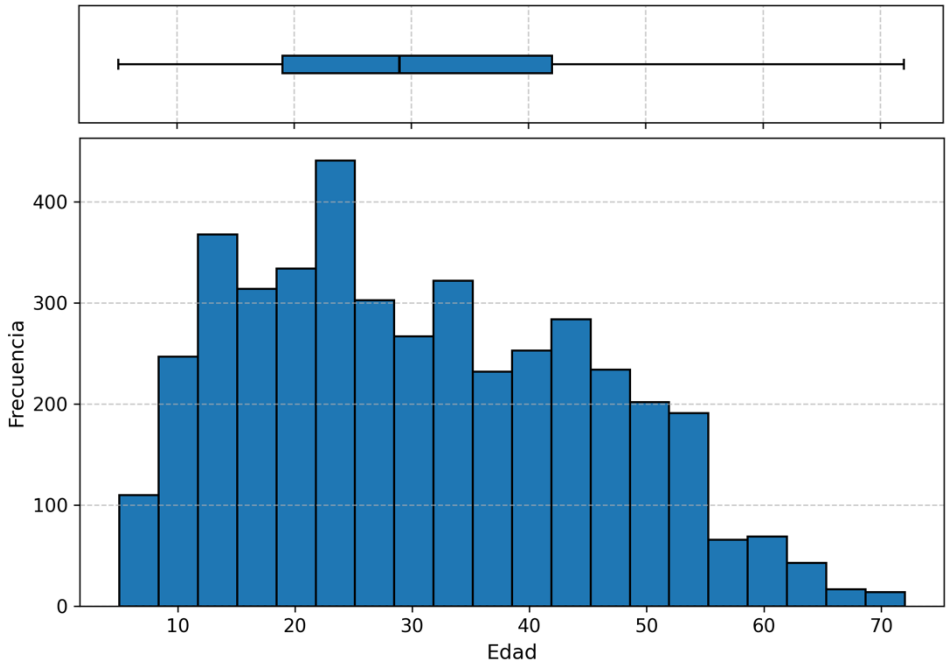

En la Figura 2 se muestra la distribución de edad mediante un histograma acompañado de un diagrama de cajas. Los resultados reflejan una distribución amplia, con mayor concentración en el rango comprendido entre los 15 y los 45 años, aunque con presencia de valores extremos en edades superiores. Esta dispersión indica que el programa de captación abarca perfiles muy diversos, sin un rango de edad claramente delimitado. Esta heterogeneidad limita la capacidad de segmentación basada únicamente en variables demográficas, aumentando la relevancia de otras variables como el tipo de discapacidad o la experiencia deportiva.

Figura 3.
Distribución de aspirantes según estado de clasificación oficial

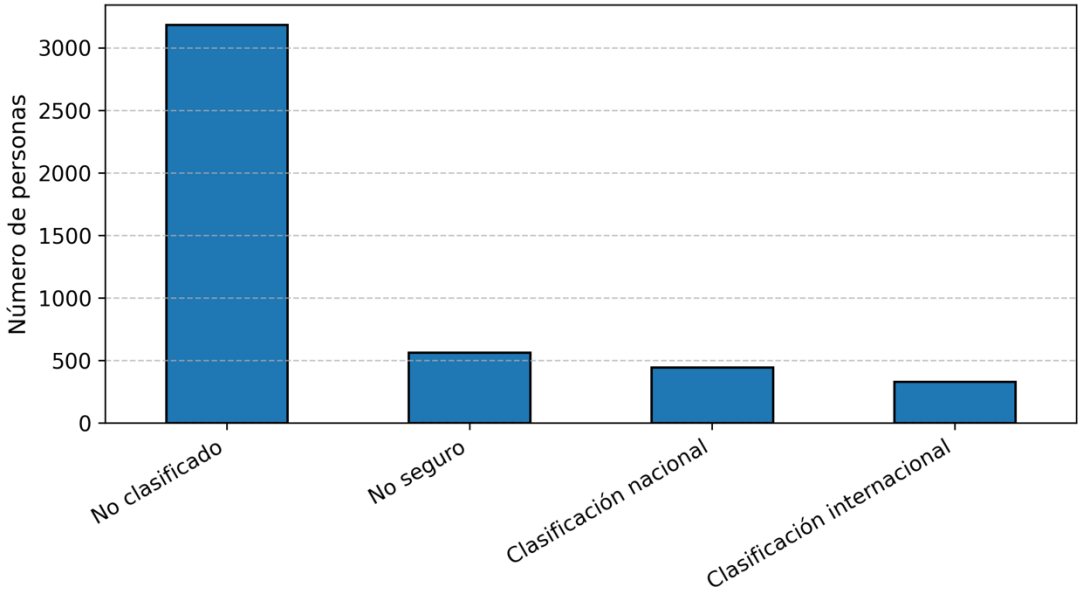

En la Figura 3 se muestra la distribución de los aspirantes según su estado de clasificación. Se observa que la gran mayoría de los registros se encuentran en la categoría “No clasificado”, seguida a gran distancia por las categorías “No seguro”, “Clasificación nacional” y “Clasificación internacional”. Este resultado pone de manifiesto la existencia de un volumen elevado de aspirantes que aún no han sido evaluados formalmente, lo que evidencia una limitación operativa en los procesos actuales de clasificación.

Figura 4.

Ranking de deportes más demandados por los aspirantes

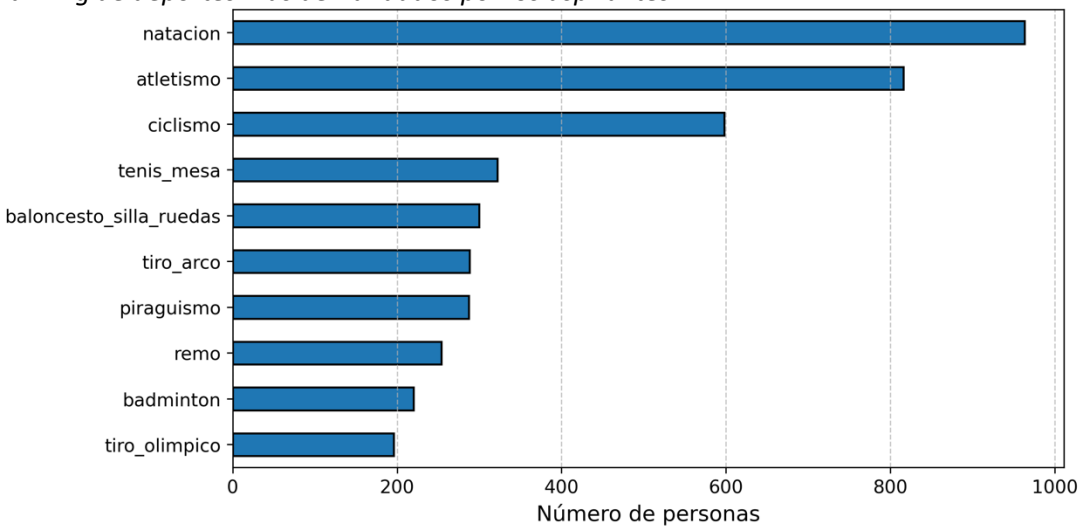

Por otro lado, la Figura 4 muestra el ranking de los deportes con mayor interés por parte de los aspirantes. Entre los más destacados se encuentran la natación, el atletismo y el ciclismo, seguidos por el tenis de mesa y el baloncesto en silla de ruedas. Esta concentración permite identificar áreas prioritarias para la asignación de recursos y el diseño de programas deportivos.

Figura 5.

Matriz de correlación entre tipos de discapacidad y preferencias deportivas

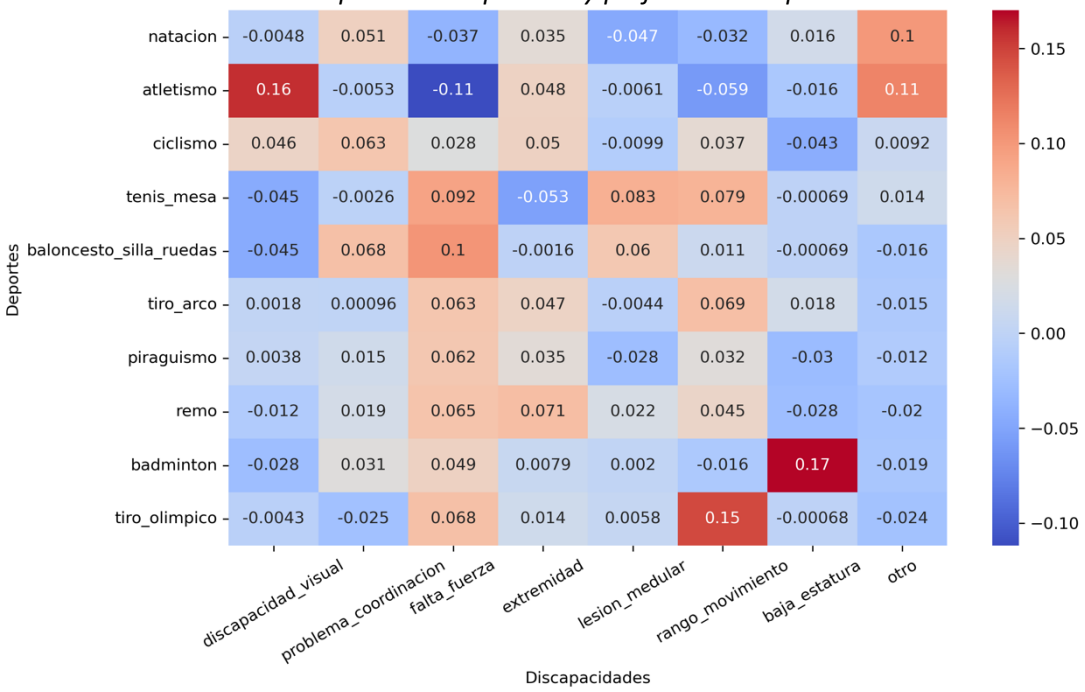

En la Figura 5 se presenta una matriz de correlación entre los tipos de discapacidad y los deportes más practicados. Los resultados muestran correlaciones generalmente bajas, sin patrones claramente dominantes. Aunque se identifican algunas relaciones moderadas entre determinadas discapacidades y deportes, estas no son lo suficientemente significativas como para establecer reglas deterministas. Este hallazgo es especialmente relevante, ya que pone de manifiesto que la asignación de deportes no puede basarse en reglas simples, sino que requiere modelos capaces de capturar relaciones complejas y no lineales.

Figura 6.

Proporción de práctica de natación según afectación de extremidades

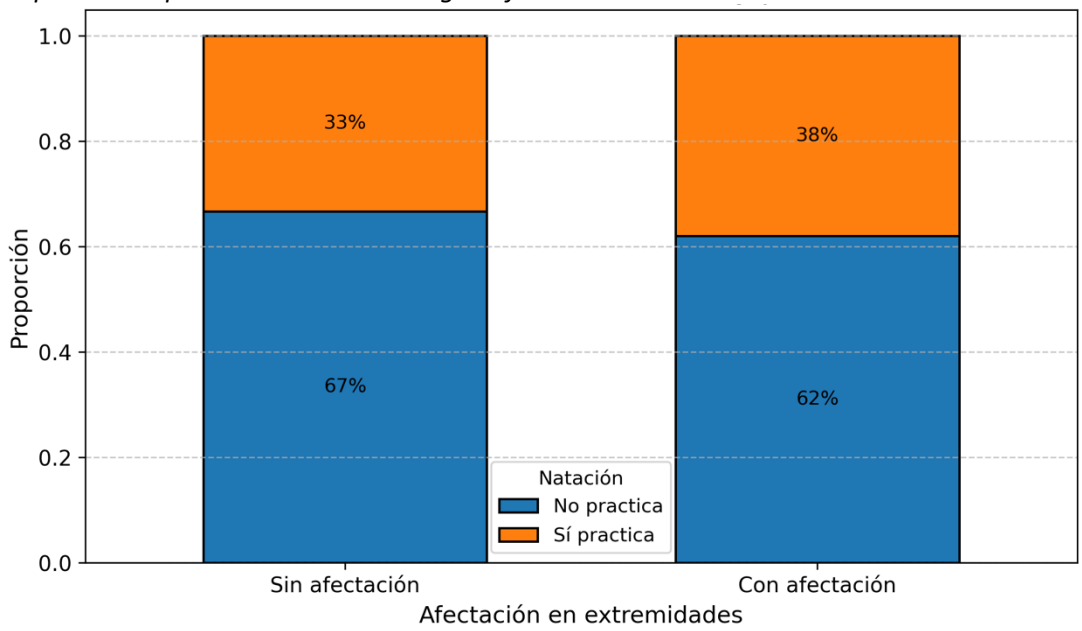

La Figura 6 analiza la relación entre la afectación en extremidades y la práctica de natación. Se observa que la proporción de individuos que practican natación es similar tanto en personas con afectación como sin ella, con una ligera mayor presencia en el primer grupo. Este resultado sugiere que la natación es un deporte altamente inclusivo y adaptable a diferentes perfiles funcionales. Este tipo de análisis evidencia la dificultad de establecer asociaciones rígidas entre discapacidad y deporte.

Figura 7.

Representación semántica de deportes practicados por los aspirantes

Por su parte, la Figura 7 muestra una nube de palabras construida a partir de los deportes actualmente practicados por los aspirantes. Se identifican como deportes más frecuentes la natación, el atletismo, el fútbol, el ciclismo y el baloncesto. Asimismo, se detecta la presencia de términos heterogéneos y cierta variabilidad en la forma de expresar los deportes, lo que evidencia la naturaleza no estructurada de esta variable. Este comportamiento refuerza la necesidad de aplicar técnicas de procesamiento de lenguaje natural para la normalización y comprensión semántica de las respuestas.

Figura 8.
Distribución del interés competitivo de los aspirantes

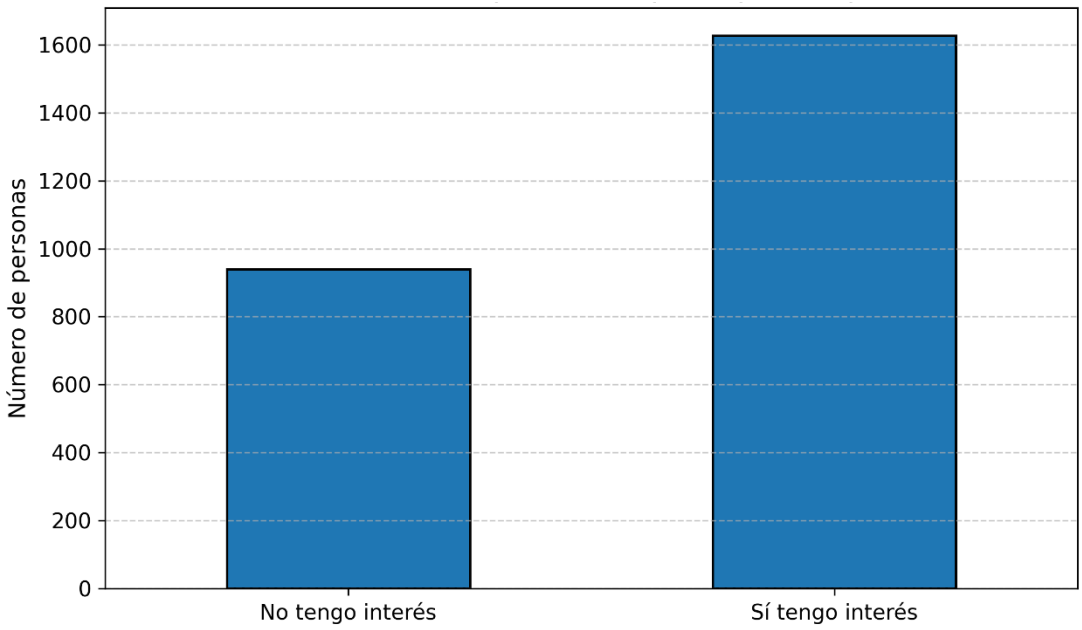

Finalmente, la Figura 8 recoge la distribución del interés de los aspirantes en competir en el ámbito paralímpico. Se observa que la mayoría de los individuos manifiestan interés en competir, lo que evidencia una alta motivación dentro de la muestra analizada. Este aspecto refuerza el valor del dataset, ya que no solo recoge información descriptiva, sino también un alto potencial de captación de talento. En este sentido, el principal reto no radica en la falta de candidatos, sino en la capacidad de procesar y clasificar eficientemente dicha demanda.

El análisis exploratorio realizado permite extraer varias conclusiones clave:

- El dataset presenta alta heterogeneidad y desbalance, especialmente en variables como el tipo de discapacidad.
- Existe una fuerte presencia de datos no estructurados, particularmente en las descripciones de discapacidad y deportes.
- No se identifican relaciones simples o lineales entre variables, lo que dificulta el uso de enfoques tradicionales basados en reglas.
- Se observa una alta motivación por parte de los aspirantes, lo que refuerza el valor estratégico del dataset.

En conjunto, estos resultados justifican la adopción de un enfoque basado en procesamiento de lenguaje natural y modelos avanzados, como el sistema LEXI basado en RAG, capaz de capturar relaciones semánticas complejas y mejorar el proceso de preclasificación de aspirantes.

Análisis de LEXI

El análisis de los datos extraídos de lexi.global fue fundamental para definir la estrategia de modelado. Detectamos dos retos principales:

Densa Terminología Médica: Las descripciones no utilizan lenguaje coloquial. Un atleta puede decir "me cuesta mover las piernas", pero LEXI dice "Moderately affected coordination in lower limbs". Esto nos confirmó que la búsqueda tradicional por texto fallaría y que necesitábamos el motor de Embeddings.

Estructura Polimórfica: El análisis reveló que un solo perfil funcional (una silueta) no es exclusivo de un deporte. Por ejemplo, una afectación moderada en el tronco es válida para Tiro con Arco, Atletismo y Natación. Esta observación dio lugar a la creación del mapa_deportes.json, asegurando que el sistema sea capaz de ver "todas las vidas deportivas" de un aspirante tras identificar su perfil médico.

Análisis del dataset externo de rendimiento físico
De forma complementaria, se realizó un análisis exploratorio sobre el dataset externo de rendimiento físico (Body Performance), con el objetivo de evaluar su utilidad para el desarrollo de un modelo predictivo de detección de talento.
Este dataset, a diferencia del proporcionado por el CPE, presenta una estructura más homogénea y está compuesto por variables cuantitativas relacionadas con el rendimiento físico, como fuerza, resistencia y flexibilidad.
En primer lugar, se realiza un análisis de los datos objetivo para comprobar si están balanceados entre clases, esto se puede comprobar en la figura 9.

Figura 9.
Distribución de categorías.

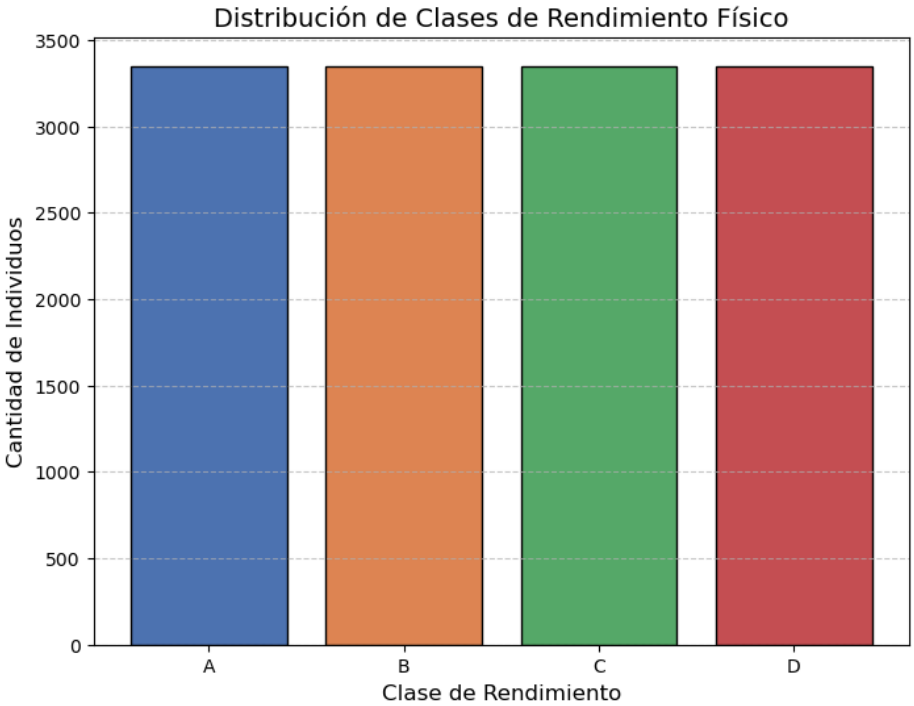

Se observa un equilibrio perfecto entre clases, lo que nos permite descartar sesgos en nuestros datos.

Tras ello comprobamos que realmente existe una diferencia notable entre las distintas clases en cuanto al rendimiento. Para ello creamos gráficas boxplot con un dato aleatorio, en este caso el desempeño en abdominales según la clase. Obtenemos la figura 10.

Figura 10.
Distribución de categorías.

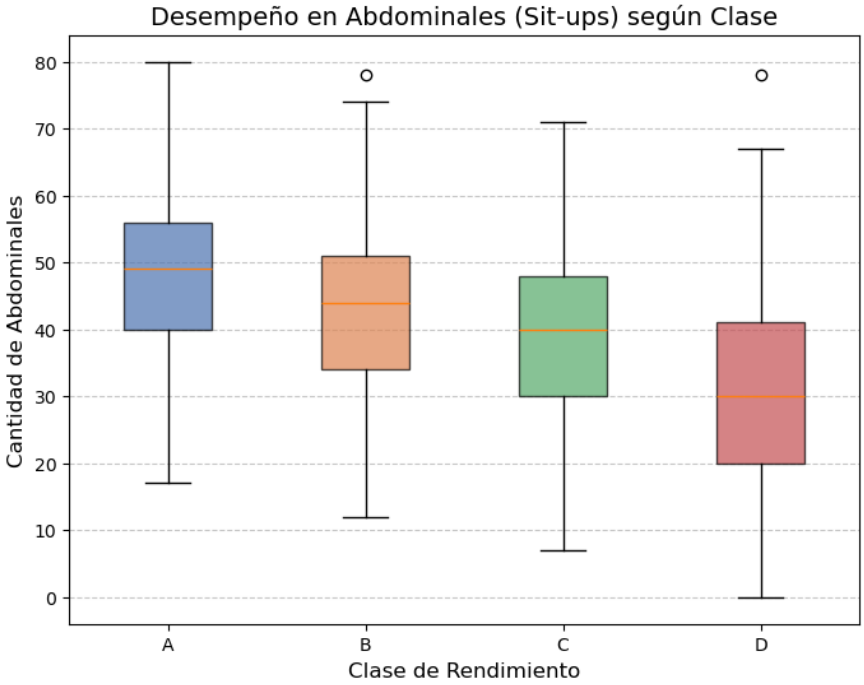

Se comprueba que hay una diferencia significativa entre las distintas clases dándonos a entender que sí hay una clasificación lógica.

También analizamos la cantidad de hombres y mujeres que hay en cada rango de edad para comprobar la homogeneidad en los datos en la figura 11.

Figura 11.
Distribución de edades en el dataset mostrando hombres y mujeres.

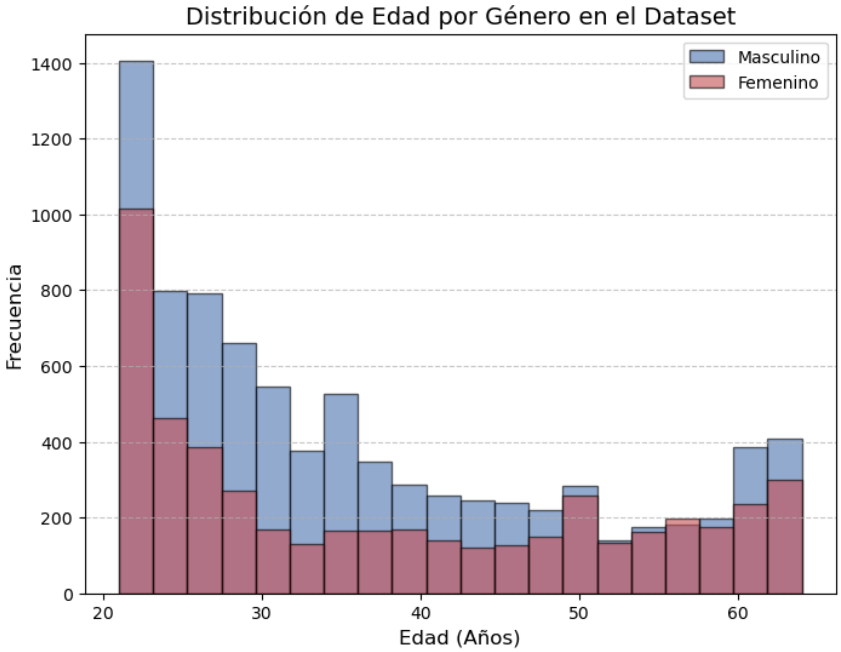

Por último y para evitar problemas futuros, se comprueba el rendimiento de las distintas clases, pero diferenciando entre hombres y mujeres por si hay una diferencia entre rendimiento. Se consigue la figura 12

Figura 12.
Distribución de edades en el dataset mostrando hombres y mujeres.

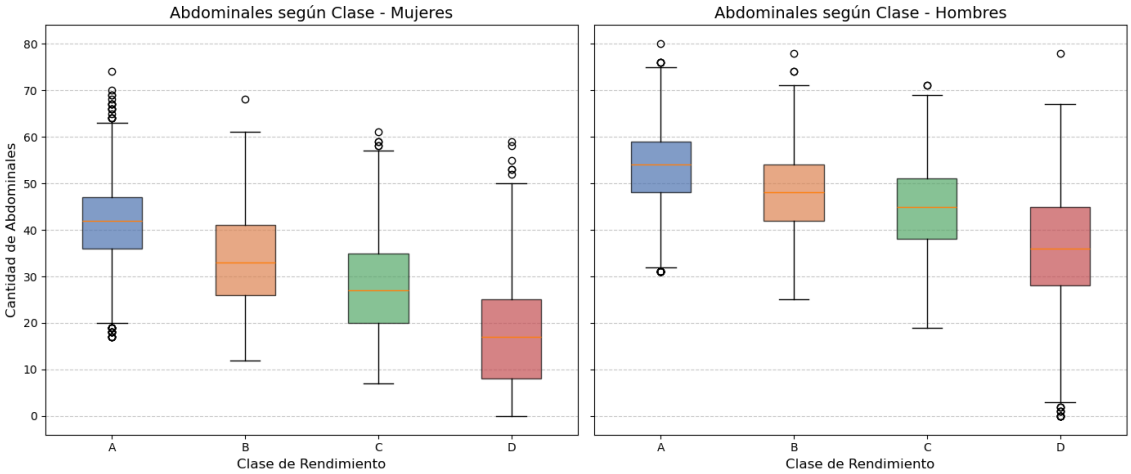

Se comprueba que, en líneas generales, dependiendo del género el nivel de exigencia para entrar en un grupo o en otro es distinto. Esta información se tendrá en cuenta a la hora de entrenar los modelos.

Antes del entrenamiento del modelo predictivo, se aplicaron transformaciones adicionales sobre el dataset externo con el objetivo de mejorar su calidad y adecuarlo a las necesidades del modelo.

El análisis exploratorio permitió establecer una diferenciación clara entre los dos entornos de datos utilizados en el proyecto. Por un lado, el dataset del CPE, caracterizado por su naturaleza no estructurada y su utilidad en tareas de interpretación semántica. Por otro, el dataset externo, con una estructura más adecuada para el desarrollo de modelos predictivos.
Esta distinción fue clave para definir la arquitectura del proyecto, orientando el uso de técnicas de procesamiento de lenguaje natural en la herramienta de preclasificación, y reservando los modelos de Deep Learning para escenarios donde la calidad y estructura de los datos lo permiten.

3.3. Modeling

Sistema LEXI.

El núcleo inteligente de ParaTalent Hub, como ya se ha comentado antes, se basa en una arquitectura de Recuperación Aumentada por Generación (RAG). El objetivo primordial de este modelo no es la generación creativa de texto, sino la clasificación técnica precisa de atletas basándose en el corpus de conocimiento experto de LEXI (Library of Evidence for Classification in Paralympic Sport). El modelado se ha estructurado en dos fases críticas: la Ingeniería de Representación (Fase Estática) y el Motor de Inferencia y Reranking (Fase Dinámica).

<u>Fase I: Construcción de la Infraestructura de Conocimiento</u>

Para que el sistema sea capaz de "comprender" la discapacidad, primero se ha construido un almacén de datos vectorial mediante el script cerebro.py. Este proceso sigue una lógica de ingeniería de datos rigurosa:

- Vectorización de Alto Nivel (Embeddings): Se ha utilizado el modelo text-embedding-ada-002 de OpenAI para transformar las 186 descripciones médicas obtenidas mediante web scraping en vectores de 1536 dimensiones. Este paso permite que el sistema realice una búsqueda semántica, donde la cercanía entre vectores representa la similitud clínica de las patologías, independientemente del vocabulario coloquial que utilice el atleta.
- Desacoplamiento de Metadatos: Se ha implementado una estructura de documentos donde el contenido textual (page_content) está estrictamente separado de las referencias visuales (metadata). Esto garantiza que el motor matemático de búsqueda no se vea contaminado por ruido algorítmico, pero permite recuperar la silueta técnica correcta una vez hallada la coincidencia.
- Indexación en FAISS: Para garantizar una latencia mínima, se ha implementado un índice FAISS (Facebook AI Similarity Search). Este motor realiza búsquedas de vecinos más cercanos (K-NN) optimizadas en RAM, permitiendo identificar los perfiles más relevantes en milisegundos.

Fase II: El Modelo LEXI (Inferencia y Lógica de Negocio)

Una vez construida la base, el sistema opera bajo el denominado Modelo LEXI, un flujo de decisión que garantiza un triaje con coherencia clínica absoluta. El proceso de modelado dinámico se divide en tres capas:

- Capa de Recuperación Semántica: El sistema toma el relato del atleta y, tras una traducción técnica al inglés, realiza una consulta al índice FAISS. Se ha configurado el modelo para recuperar los 15 candidatos más cercanos (k=15) basándose en la métrica de similitud de coseno.
- Capa de Filtrado por Reglas Estrictas: El sistema aplica una Matriz de Exclusión Lógica mediante instrucciones sistémicas de control. Estas reglas prohíben explícitamente la mezcla de categorías (ej. un atleta visual nunca recibirá sugerencias motoras) y bloquean la asignación de perfiles de amputación a usuarios que no hayan declarado la pérdida de un miembro, neutralizando las falsas similitudes que la búsqueda vectorial podría generar por cercanía semántica.
- Capa de Reranking y Generación de Contexto: Los candidatos filtrados se inyectan en un prompt sistémico diseñado para el modelo gpt-4o-mini. El modelo actúa aquí como un clasificador lógico, analizando las sutiles diferencias entre los 15 perfiles recuperados y el relato del usuario para jerarquizar los 9 mejores resultados.

Para garantizar la fiabilidad del sistema, se ha implementado un Parser Determinista basado en Expresiones Regulares (Regex). A diferencia de un parseo de texto tradicional que podría fallar si la IA varía su formato de respuesta, nuestro motor utiliza la librería re para extraer exclusivamente los identificadores numéricos. Esto blinda la comunicación entre el LLM y la interfaz de usuario, eliminando errores de ejecución por respuestas inesperadas de la IA.

Resultados del Modelado

Esta aproximación de modelado híbrido (búsqueda vectorial + reglas de negocio + reranking de LLM) permite que ParaTalent Hub no solo sea una herramienta rápida, sino clínicamente segura. Al limitar el contexto del LLM únicamente a los documentos recuperados de LEXI, se garantiza que las sugerencias de categorías deportivas estén siempre respaldadas por la evidencia técnica oficial del Comité Paralímpico, eliminando la posibilidad de sugerencias erróneas o incompatibles.

Modelos de Predicción.

Para enfrentarnos a la predicción contamos con varias opciones entre las que elegir. Disponemos de distintos métodos de machine learning para clasificación. Para acotar la elección, utilizaremos únicamente dos: Random Forest y Multi-Layer Perceptron. El primero se ha seleccionado por su presunta precisión, rapidez de uso y transparencia en cuanto a la importancia de cada variable en la decisión de la categoría. El segundo se elige por su capacidad para detectar relaciones no lineales entre variables, que pueden no apreciarse en la primera opción, así como por su escalabilidad.

El objetivo de este entrenamiento es identificar quiénes pertenecen a la clase élite, es decir, a la clase 'A'. Para ello, podemos abordar el problema bajo dos enfoques:

- Realizar una clasificación en 4 clases, identificando directamente a los individuos de la clase "A".
- Convertir el dataset original de 4 clases en uno binario, agrupando las clases "B", "C" y "D" en una sola categoría y dejando la clase 'A' como la otra.

Dado que no conocemos de antemano cuál de las opciones ofrecerá mejores resultados, se llevarán a cabo entrenamientos con todas las combinaciones posibles entre estas variables: Random Forest o MLP, y clasificación en 4 clases o en 2 clases.

Asimismo, tras observar diferencias de rendimiento entre clases en función del género, se ha optado por realizar, en cada iteración, tres entrenamientos distintos: uno con todos los deportistas incluidos (mixto), otro únicamente con hombres y otro únicamente con mujeres. De esta forma, podremos seleccionar el modelo que mejor se adapte a nuestro objetivo, que es identificar con la mayor precisión posible a los candidatos con potencial de élite.

Clasificación en 4 clases.

Random Forest (RF).

Para el entrenamiento de este modelo, tras preparar los datos, haremos en primer lugar una separación entre datos de entrenamiento y test. En este tipo de modelo no es necesaria una estandarización de los datos debido a su funcionamiento, lo que también supone una ventaja frente a la MPL, aunque no supone una cantidad de cómputo muy elevada.

Para encontrar los hiperparámetros que mejor van a realizar la función hemos hecho uso de Grid Search. Esta herramienta realiza el entrenamiento con todos los parámetros que le ofrecemos en una matriz devolviéndonos los hiperparámetros que mejor se comportan bajo el score que escogemos. Se ha elegido usar cross-validation = 3 y buscando la mejora en 'accuracy'.

Mezclado

Como se ha comentado anteriormente, se ha realizado el mismo entrenamiento, pero debido a lo observado en la figura 12, en un caso se hará con todos los deportistas incluidos y en otro se separará por género.

Tras entrenar el modelo, analizamos los resultados que se muestran en las siguientes imágenes:

Figura 13.
Matriz de confusión en RF para 4 clases con géneros mezclados.

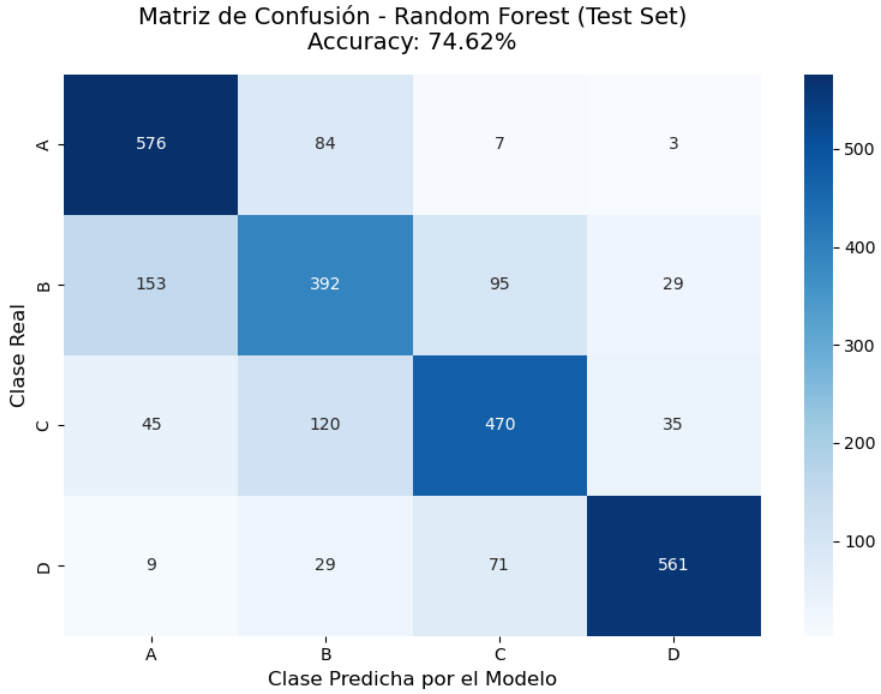

Figura 14.
Pesos relativos en RF para 4 clases con géneros mezclados.

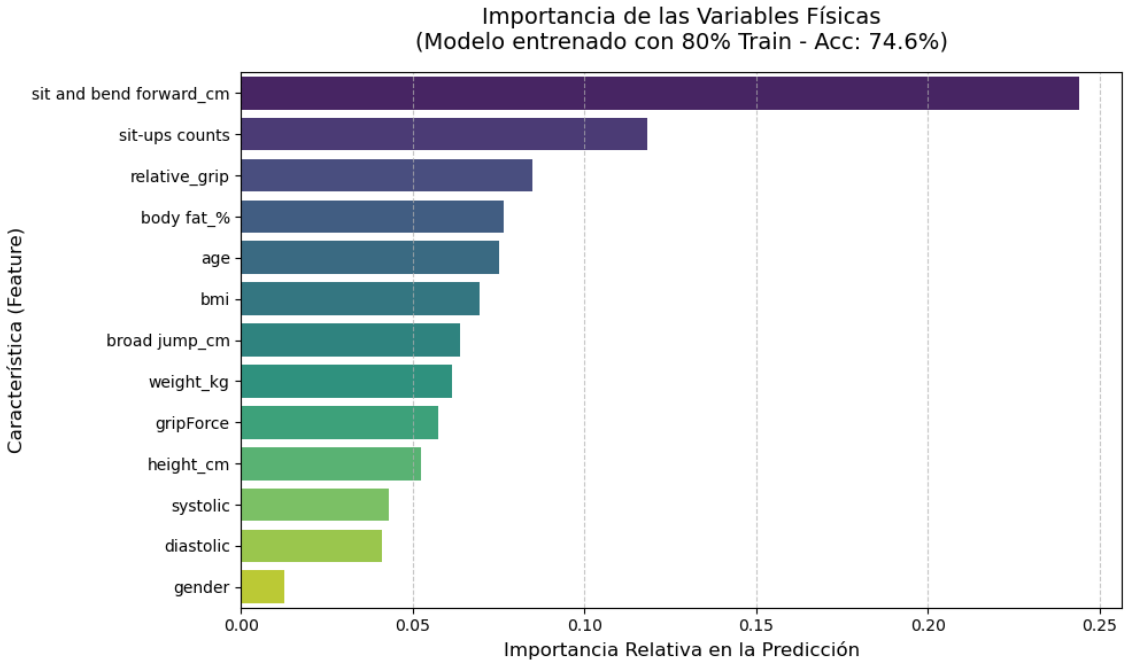

Lo primero que podemos ver es que el modelo ha aprendido y no lo está haciendo aleatoriamente, porque si no el accuracy debería estar alrededor del 25%. Debido a la cercanía de las distintas clases hay bastantes errores de clasificación entre las clases colindantes, aumentándose esta casuística entre las clases 'A', 'B' y 'C'.

Como hemos dicho anteriormente, la lógica de clasificación del Random Forest es transparente y se puede comprobar en la imagen.

Separado por género.

Figura 15.
Matriz de confusión en RF para 4 clases de solo hombres.

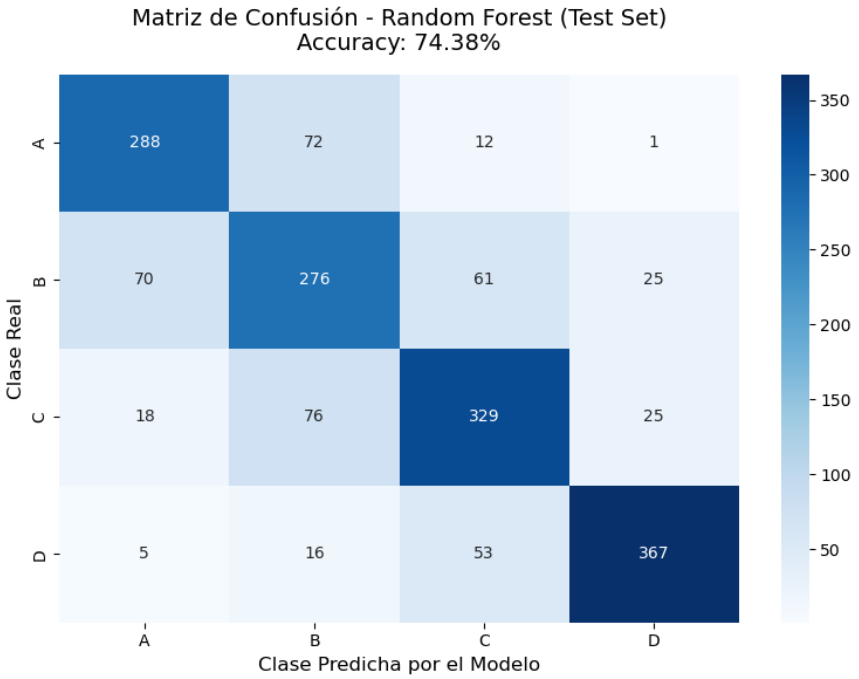

Figura 16.
Matriz de confusión en RF para 4 clases de solo mujeres.

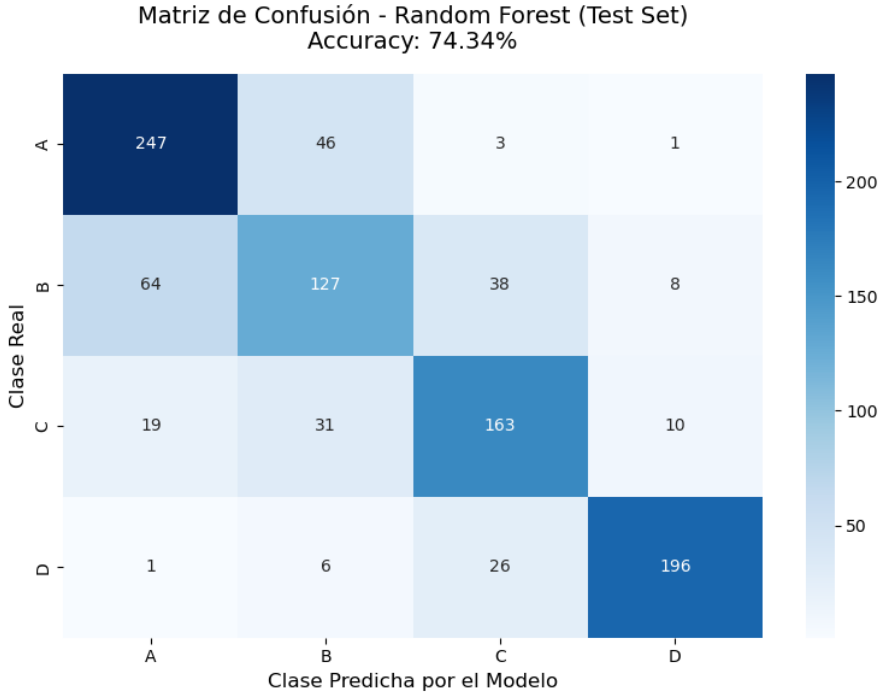

Figura 17.
Pesos relativos en RF para 4 clases con solo hombres.

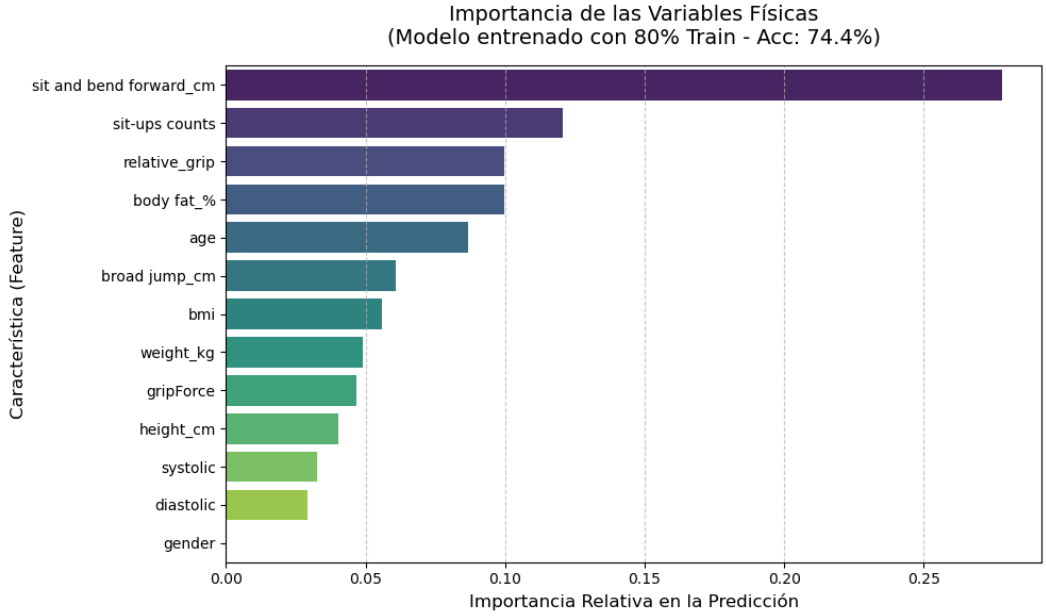

Figura 18.
Pesos relativos en RF para 4 clases con de solo mujeres.

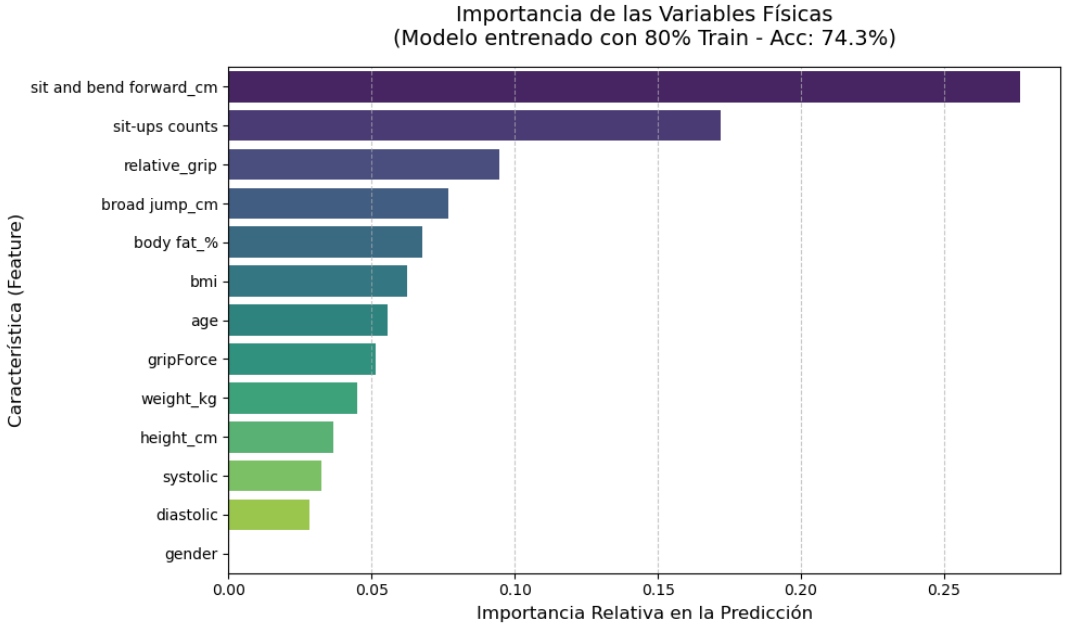

Como hemos dicho anteriormente, la lógica de clasificación del Random Forest es transparente y se puede comprobar en la imagen.
Tras observar el comportamiento tanto del accuracy, como de la importancia relativa de las variables en la predicción, podemos comprobar que es realmente parecido entre las tres opciones. Por lo que para futuros usos usaríamos el caso donde los géneros están mezclados ya que no hay diferencia entre la calidad de la predicción y es un entrenamiento más rápido.

Multi-Layer Perceptron (MLP).

Al igual que en el RF (Random Forest), antes de entrenar el modelo hemos separado los datos entre entrenamiento y test. Al igual también que anteriormente, se ha hecho una separación de 80% para train y 20% para test.

Por el contrario, en este modelo sí que es necesario normalizar los datos debido al funcionamiento de la red. Debemos tener especial cuidado en este proceso debido al data leakage que tenemos que evitar. Para ello, los datos que haremos para obtener la media y la desviación típica que usaremos para la normalización tienen que ser únicamente los de train y, tras ello, normalizar tanto los datos de train como los de prueba. De esta manera, no se filtrará ningún dato de prueba en los de entrenamiento, ya que podría afectar a la media o a la desviación típica.

Una vez tenemos los datos perfectamente estructurados, se procede al diseño de la arquitectura de la red. Para conseguir los mejores resultados, se han hecho iteraciones cambiando parámetros y la estructura de la red. En específico las herramientas que se han utilizado son las siguientes:

- A la arquitectura de la red se ha incluido Batch Normalization y dropout tras ciertas capas de la red para evitar overfitting.
- Se han introducido dos callbacks, uno de earlystopping si el entrenamiento se estancaba, y otro de reducción del learning rate para buscar esa pequeña mejora una vez el entrenamiento se empieza a realentizar.

Tras realizar varios entrenamientos se ha terminado escogiendo la estructura que posteriormente se podrá ver en una imagen cuando se comente el modelo binario. La única diferencia que habrá, y muy importante, será en la última capa. En el modelo binario esta capa es de una única neurona y con una activación tipo sigmoide. Mientras que, en este caso, debido a que tenemos 4 clases posibles, se ha escogido una capa con 4 neuronas y con activación softmax.

Esta estructura se mantendrá constante tanto en la iteración en la que los géneros están mezclados como en los que están separados debido a que en todos los casos que hemos probado esta arquitectura es la que mejor se ha comportado.

Mezclado

A continuación, se muestran las gráficas del entrenamiento de esta red:

Figura 19.
Gráficas de entrenamiento para MLP de 4 clases mixto.

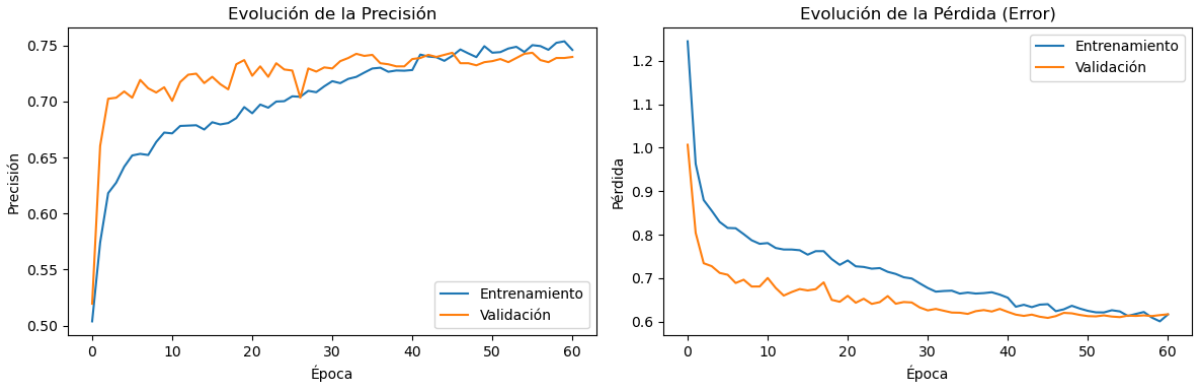

Se puede observar un entrenamiento 'sano' donde las líneas de train y test se van juntando hasta terminar debido al earlystopping.

Figura 20.
Matriz de confusión en MLP para 4 clases con géneros mezclados.

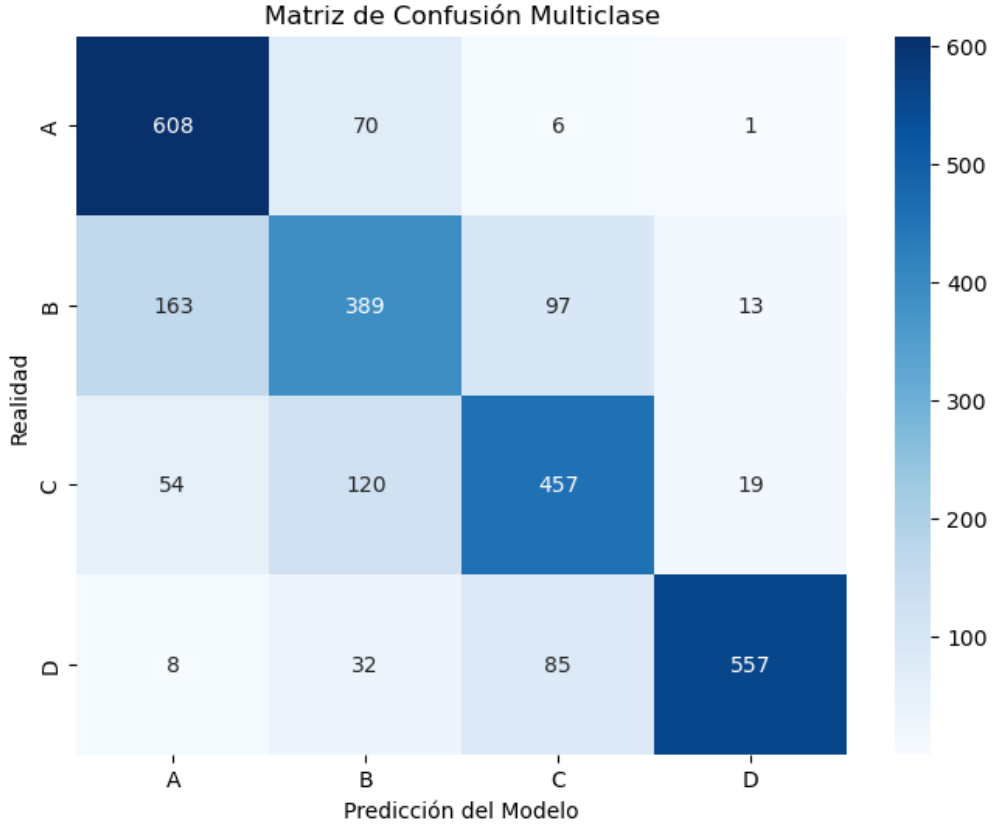

Separado por género.

Figura 21.
Gráficas de entrenamiento para MLP de 4 clases hombres.

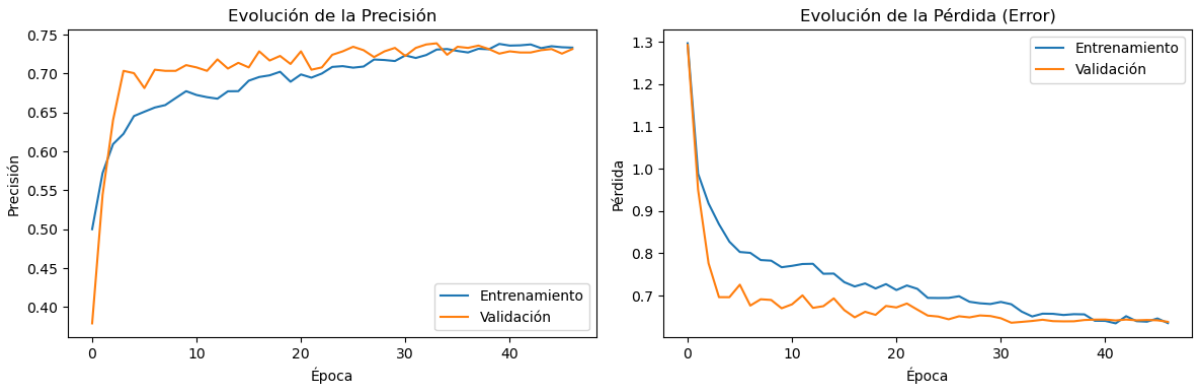

Figura 22.
Matriz de confusión en MLP para 4 clases de solo hombres.

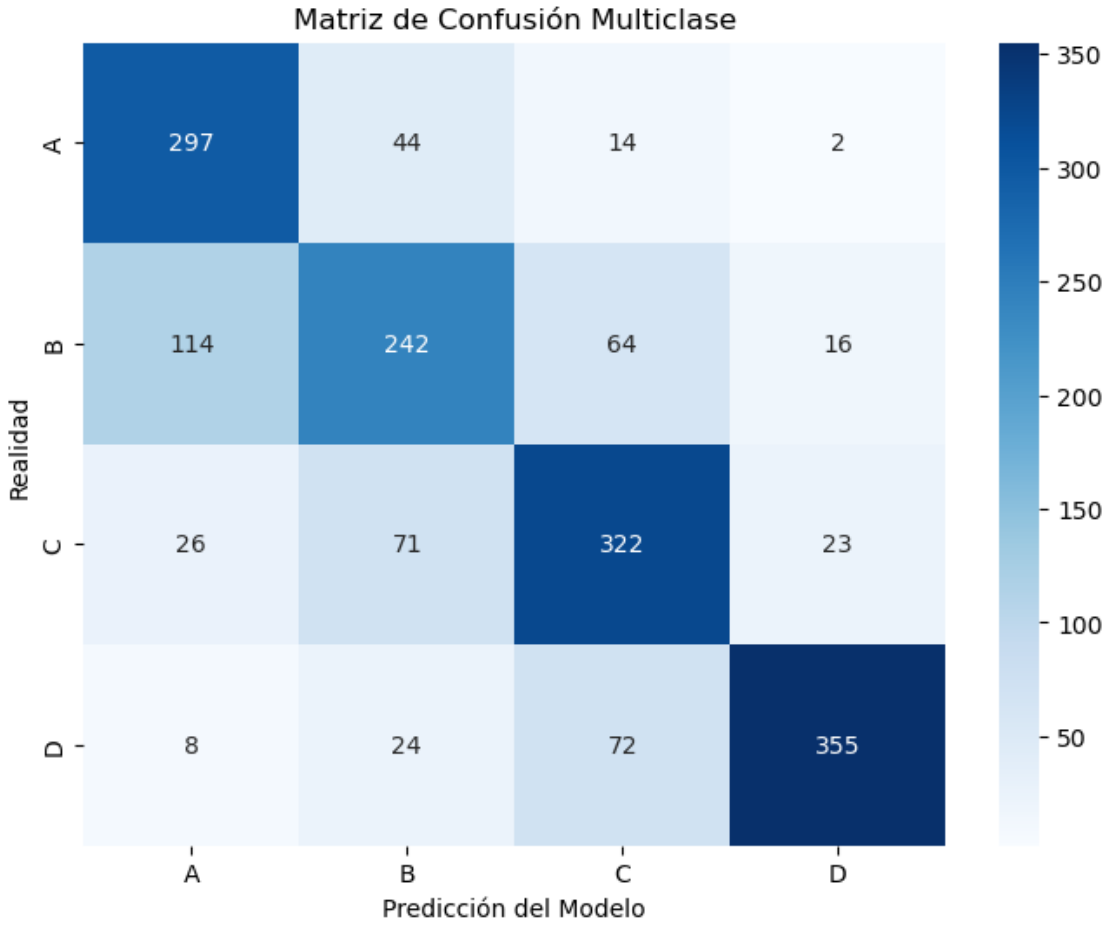

Figura 23.
Gráficas de entrenamiento para MLP de 4 clases mujeres.

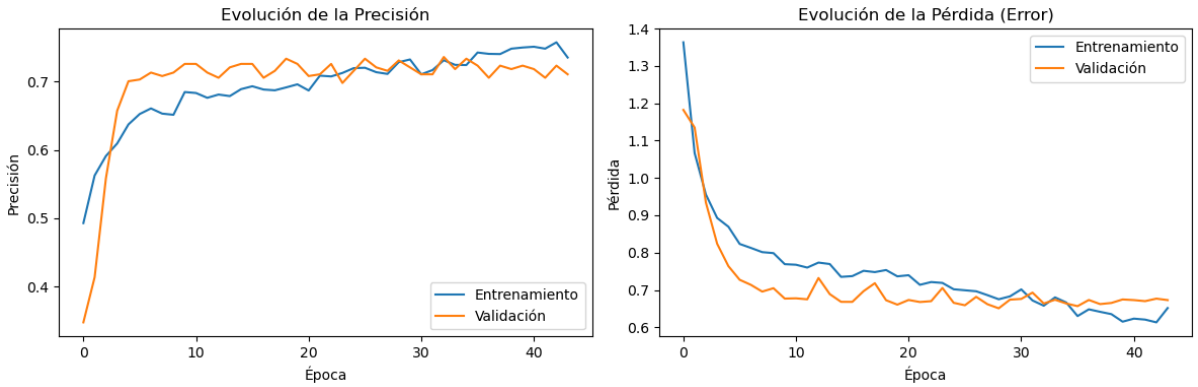

Figura 24.
Matriz de confusión en MLP para 4 clases de solo mujeres.

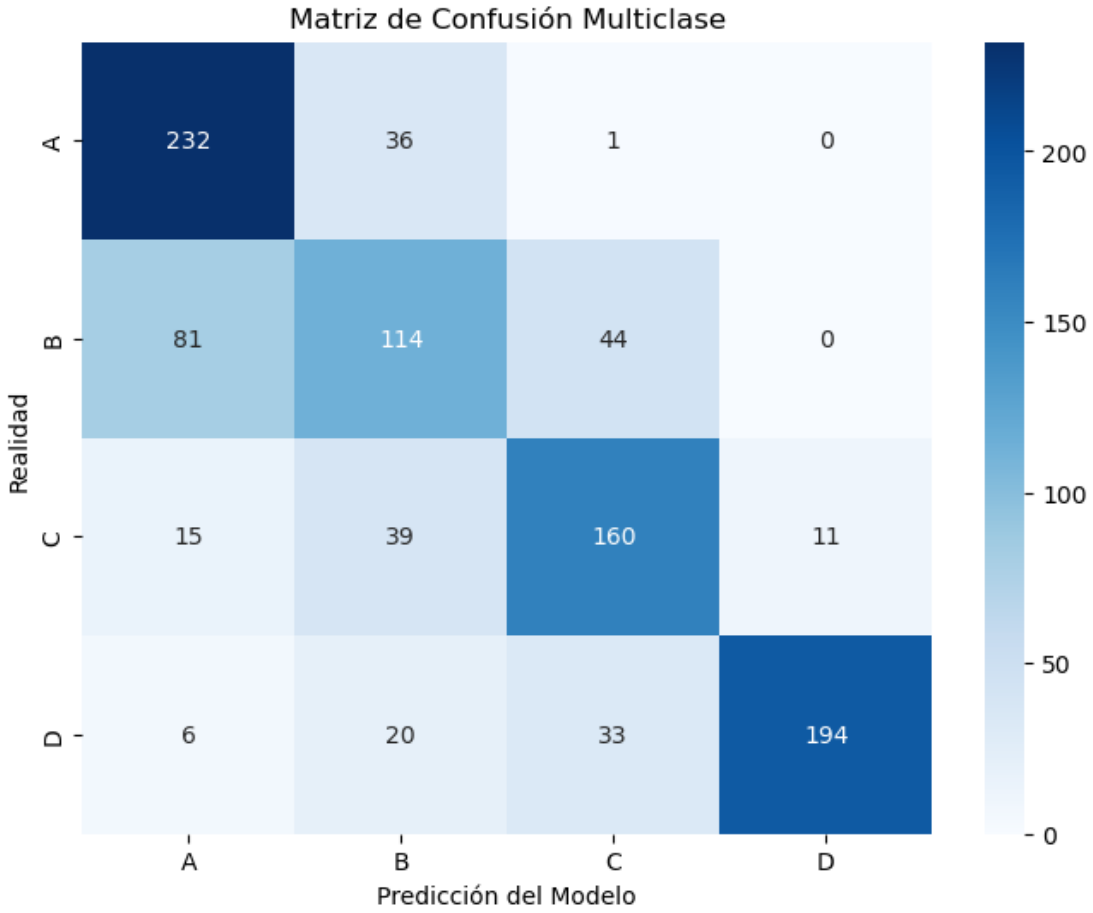

Tras observar todas las figuras y métricas entre todos los casos, al igual que el RF, se comprueba que no hay una diferencia sustancial entre entrenar los datos con los géneros mezclados o separados. También ocurre lo mismo en las matrices de confusión, que hay mayor confusión entre los deportistas de las clases altas.

Resultados

Visto el comportamiento de todos los casos con 4 clases objetivo podemos comparar los resultados. Como hemos ido confirmando, diferenciar el género no supone ninguna mejora al modelo, por lo que aquí compararemos únicamente el modelo de RF y MLP mixto.

Para comparar estos dos modelos vamos a mostrar dos tablas con distintos parámetros. En primer lugar, mostramos la tabla donde vemos los datos del RF.

Tabla 1.
Datos de aprendizaje del RF con 4 clases mixto.

	PRECISION	RECALL	F1-SCORE
A	0,74	0,86	0,79
B	0,63	0,59	0,61
C	0,73	0,7	0,72
D	0,89	0,84	0,86

Tabla 2.
Datos de aprendizaje del MLP con 4 clases mixto.

	PRECISION	RECALL	F1-SCORE
A	0,73	0,89	0,80
B	0,64	0,59	0,61
C	0,71	0,7	0,71
D	0,94	0,82	0,88

Comparando ambas tablas se puede observar que los parámetros son muy parecidos entre ambos modelos. La decisión entre escoger uno u otro puede variar de diversos factores. En el caso de que vaya a escalarse el estudio, es más probable que, debido a ese aumento de datos, el MLP pudiera conseguir mejorar antes que el RF, ya que este es probable que se estanque y aunque haya datos nuevos no mejore mucho. Por otro lado, si es necesario tener una precisión mayor en una categoría en específico podría tenerse en cuenta y escoger dependiendo de ello.

Clasificación en 2 clases.

Una vez se ha comprobado el comportamiento de los modelos teniendo como objetivo clasificar a los deportistas en 4 clases, pasamos a comprobar si es mejor entrenar con intención de predecir binariamente.

Tal y como se ha comentado anteriormente, lo que se va a hacer para conseguir el dataset con dos categorías de objetivo es unificar las clases “B”, “C” y “D” en una y por otro lado la clase “A”. Al hacer este cambio surge un problema en el balanceo porque las 4 clases por separado ya estaban perfectamente balanceadas, por lo que al hacer el cambio tenemos el triple de datos más en una clase que en la otra. Como tenemos suficientes datos lo que se realiza es eliminar datos del grupo grande hasta igualarlos al otro. Pero esta limpieza se hará de manera que se eliminen los mismos datos de “B”, “C” y “D” para no sesgar el entrenamiento. De esta manera ya tenemos el dataset preparado para proseguir con el entrenamiento.

Random Forest (RF).

Una vez ya hemos procesado los datos para tener dos clases equilibradas se procede de la misma manera que hemos presentado antes en el caso de 4 clases.

Mezclado

Figura 25.
Matriz de confusión en RF para 2 clases con géneros mezclados.

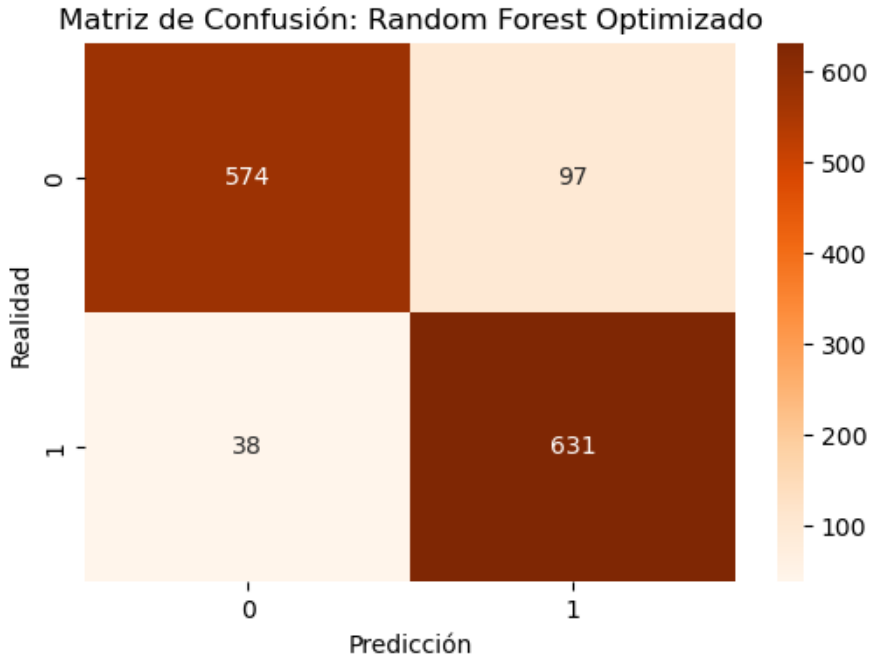

Figura 26.
Pesos relativos en RF para 2 clases con géneros mezclados.

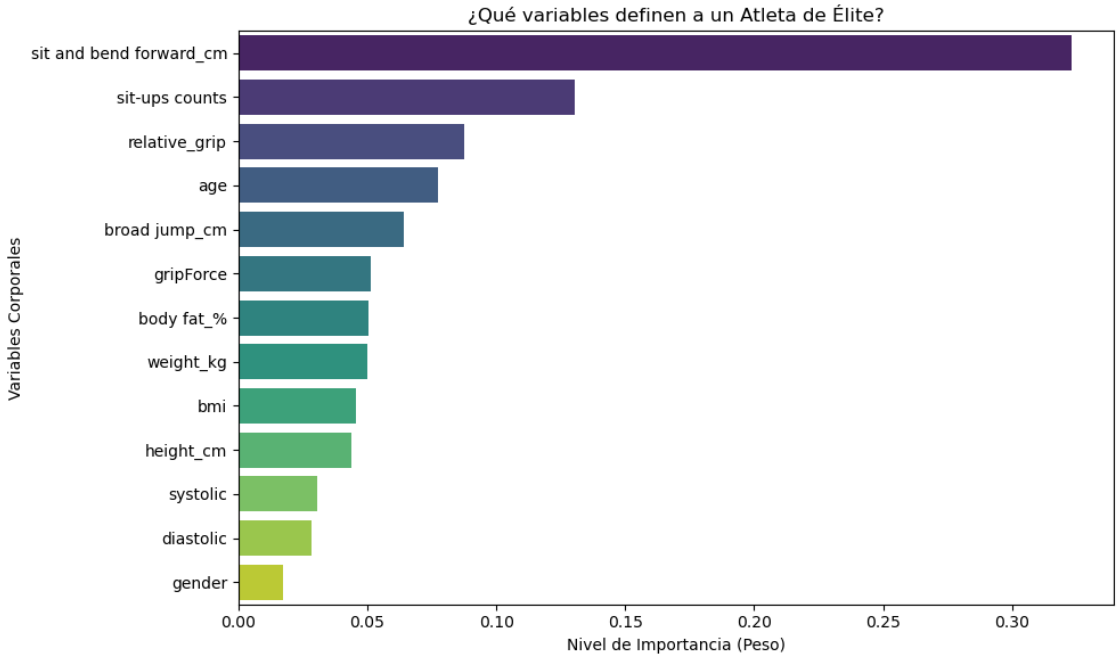

Separado por género.

Figura 27.
Matriz de confusión en RF para 2 clases de solo hombres.

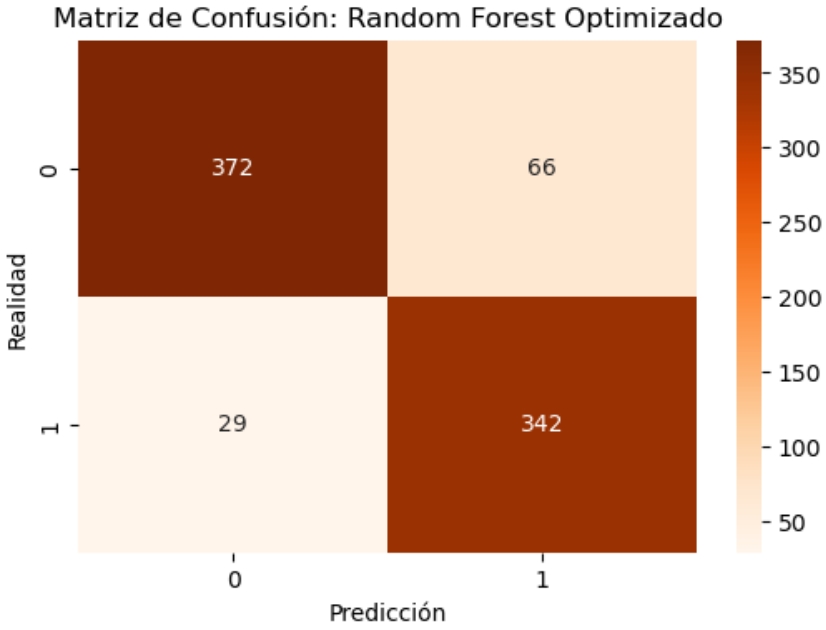

Figura 28.
Matriz de confusión en RF para 2 clases de solo mujeres.

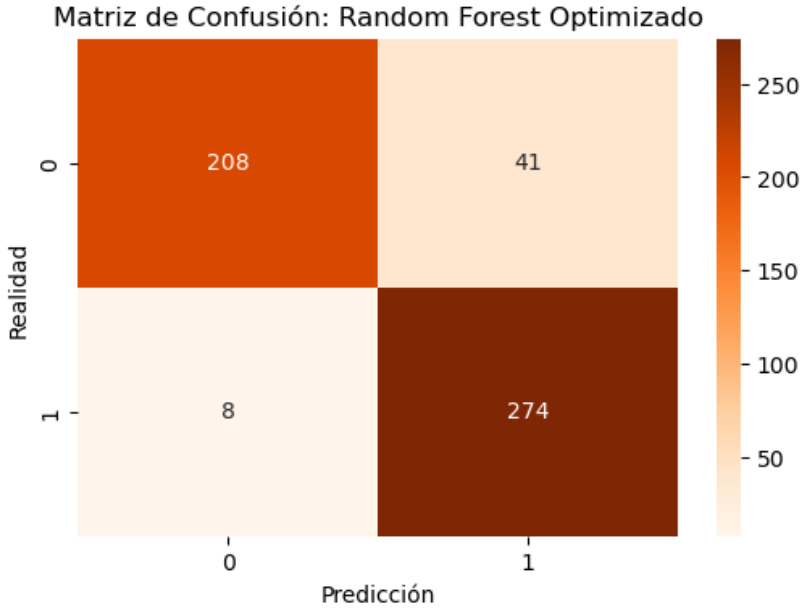

Figura 29.
Pesos relativos en RF para 2 clases con solo hombres.

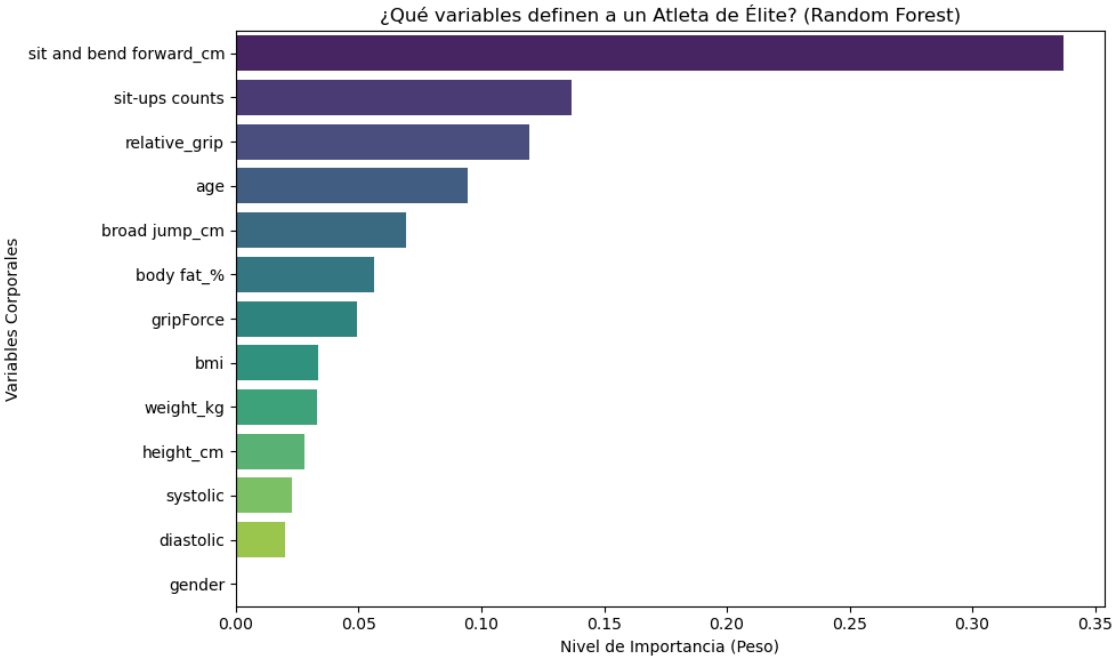

Figura 30.
Pesos relativos en RF para 2 clases con de solo mujeres.

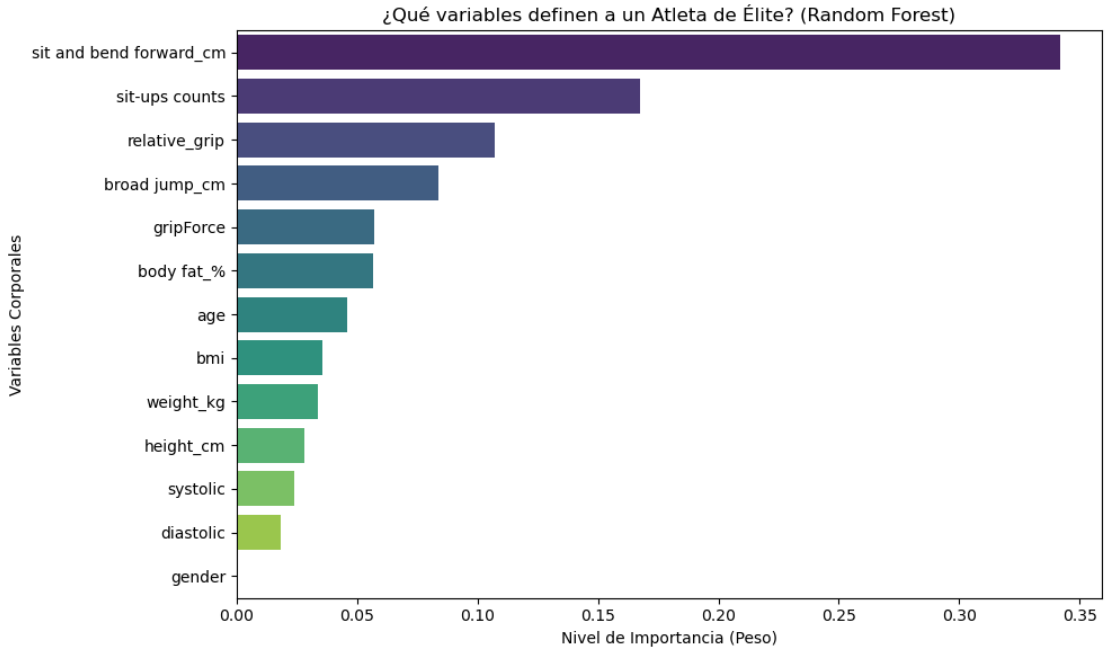

Multi-Layer Perceptron (MLP).

En el caso de 4 clases como objetivo hemos definido la red que mejor resultados nos daba. En este caso hemos usado la misma arquitectura por la misma causa, con un pequeño, pero súper importante cambio. En el caso de antes al tener 4 posibles clases teníamos una última capa de 4 células, pero este, al ser binario, vamos a cambiarlo por una capa de una célula y con una función de activación sigmoide. A continuación, se muestra un esquema de la arquitectura:

Figura 31.
Arquitectura del MLP.

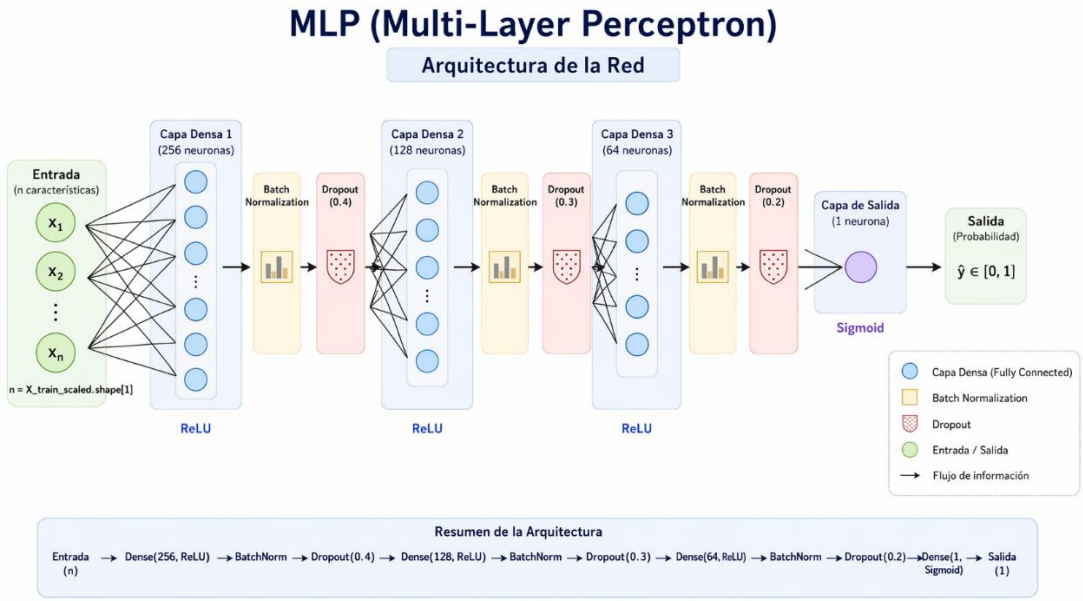

Mezclado.

Figura 32.
Gráficas de entrenamiento para MLP de 2 clases mixto.

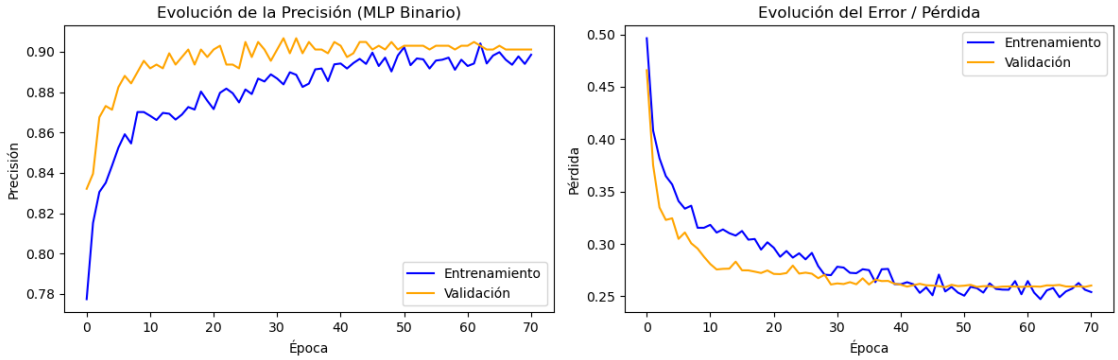

Figura 33.
Matriz de confusión en MLP para 2 clases mixto.

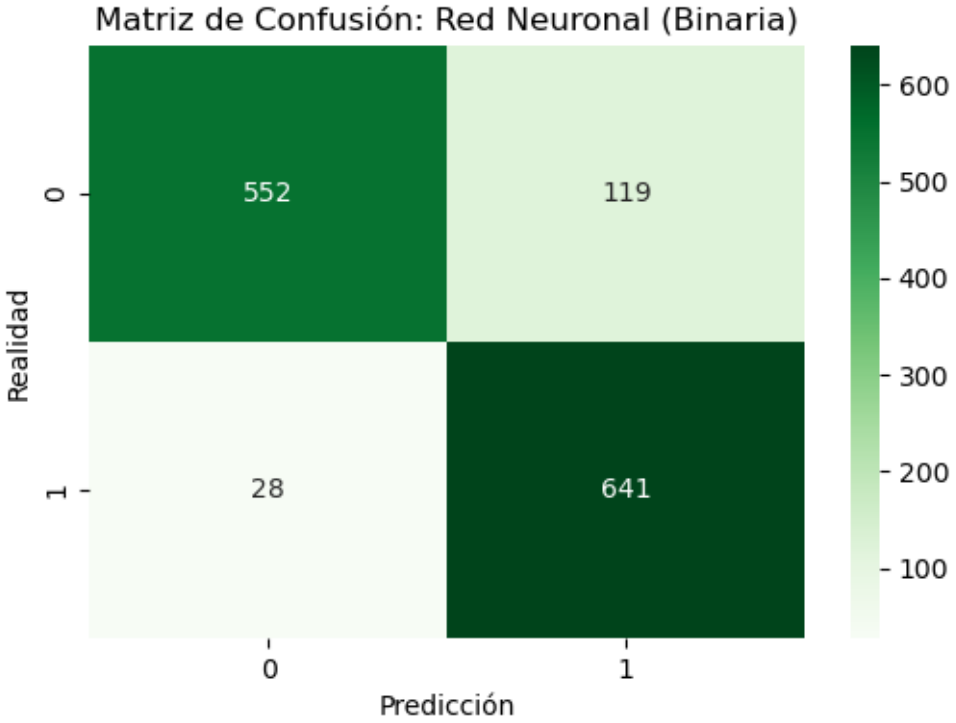

Separado por género.

Figura 34.
Gráficas de entrenamiento para MLP de 2 clases hombres.

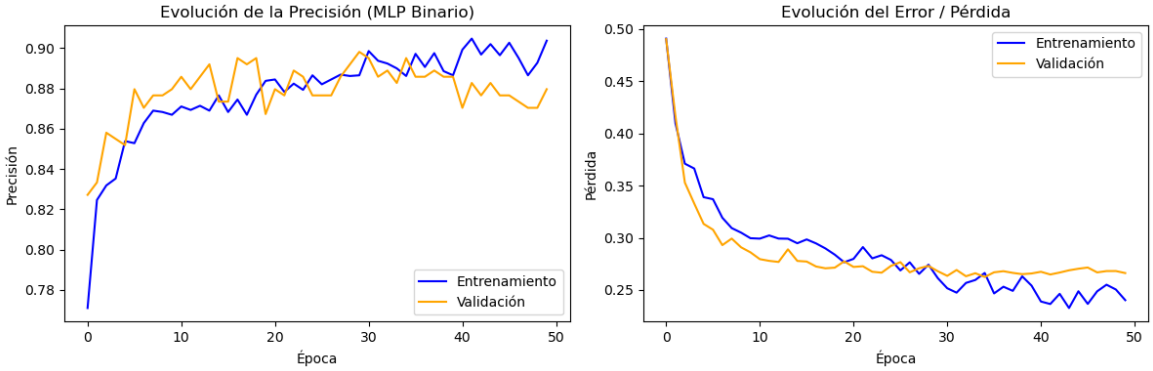

Figura 35.
Matriz de confusión en MLP para 2 clases de solo hombres.

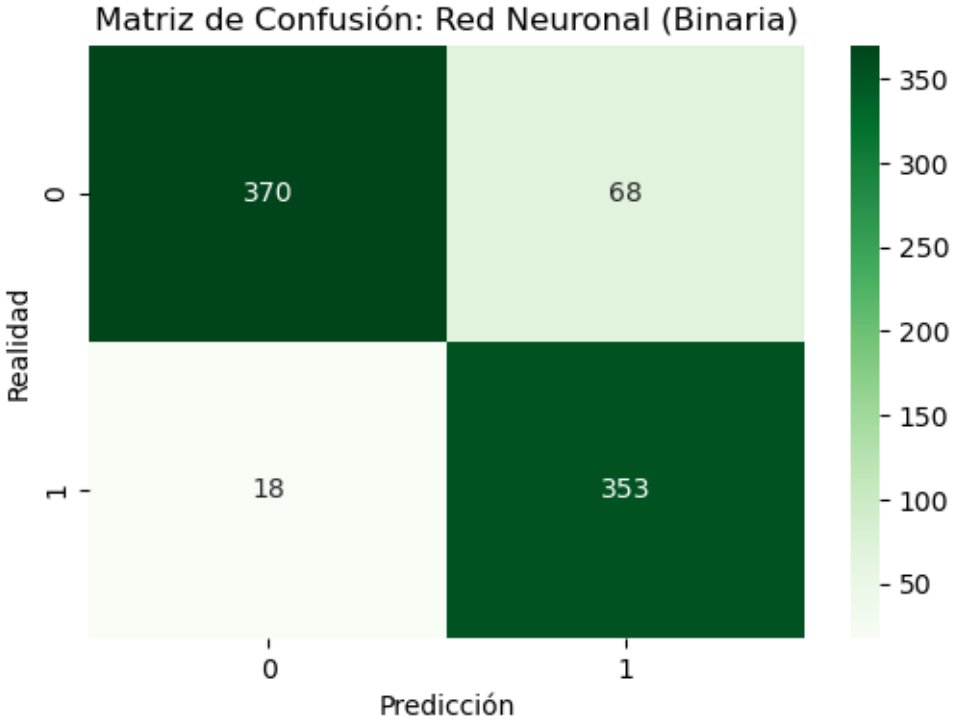

Figura 36.
Gráficas de entrenamiento para MLP de 2 clases mujeres.

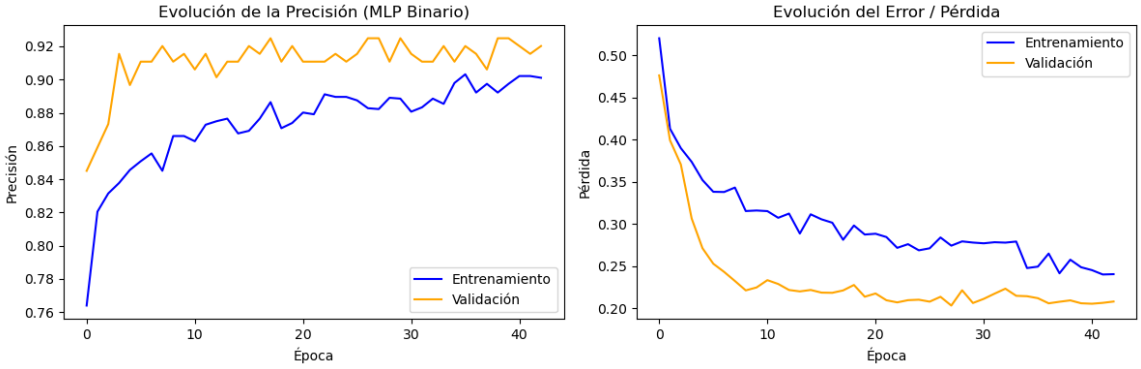

Figura 37.
Matriz de confusión en MLP para 2 clases de solo mujeres.

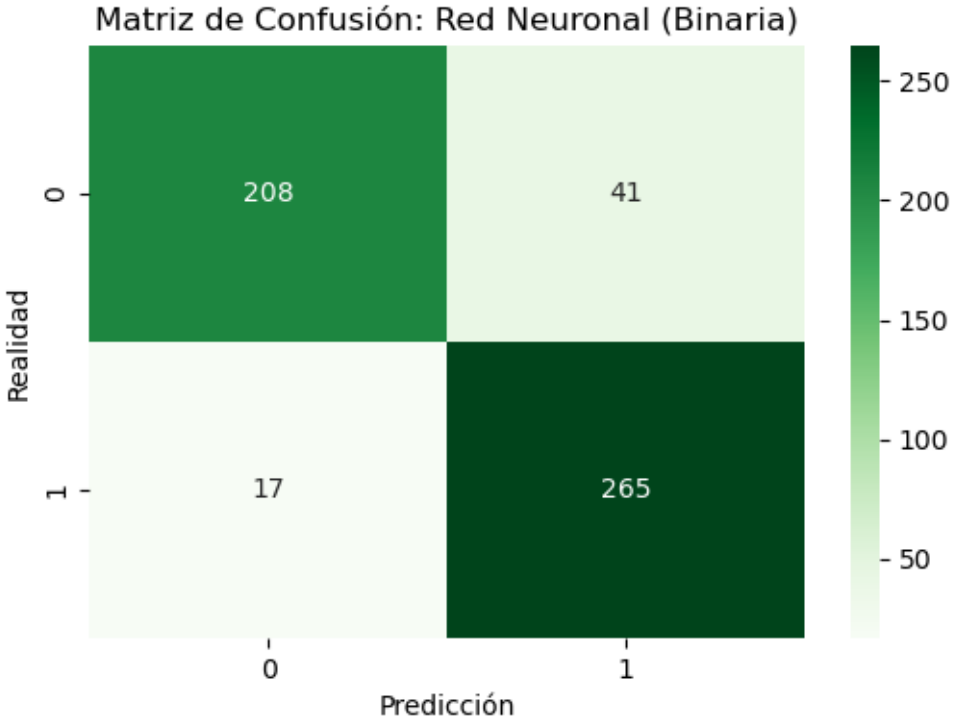

Resultados.

Como se puede comprobar, en el caso de variable objetivo binaria nos ocurre igual que en el caso de 4 clases, los modelos mixtos y separados se comportan prácticamente igual. Por eso mismo vamos a mantener el análisis únicamente en los modelos mixtos. Para comparar el RF con el MLP se muestran dos tablas al igual que con el caso de 4 clases.

Tabla 3.
Datos de aprendizaje del RF con 2 clases mixto.

	PRECISION	RECALL	F1-SCORE
Élite	0,94	0,86	0,89
No élite	0,87	0,94	0,9

Tabla 4.
Datos de aprendizaje del MLP con 2 clases mixto.

	PRECISION	RECALL	F1-SCORE
Élite	0,95	0,82	0,88
No élite	0,84	0,96	0,9

Tal y como nos ocurría en el anterior caso los datos son realmente parejos entre ambos tipos de entrenamiento. Al igual que ocurre en el caso de 4 variables objetivo, la decisión entre usar un modelo u otro dependerá de lo que se pretenda conseguir. No podemos concluir que uno es mejor que otro directamente, simplemente para ciertos objetivos será uno más conveniente que otro.

3.4. User Interface

El desarrollo de la interfaz de ParaTalent Hub se ha centralizado en el framework Streamlit, elegido por su capacidad para integrar de forma nativa modelos de Inteligencia Artificial y bases de datos en una aplicación web. El diseño se ha bifurcado en dos entornos independientes para satisfacer las necesidades específicas de cada perfil de usuario.

Portal del Atleta: UX Orientada al Acompañamiento (Home.py)

La interfaz de captación se construyó bajo principios de diseño centrado en el usuario (UCD) para minimizar la fatiga del deportista durante la recolección de datos sensibles.

Estructura por Segmentación: En lugar de un formulario lineal, se implementó una arquitectura de pestañas (st.tabs). Esto permitió organizar la información en bloques lógicos: Datos Personales, Contexto Médico, Discapacidad y Trayectoria Deportiva.

Personalización de Marca (CSS Inyectado): Para garantizar la identidad institucional del Comité Paralímpico Español (CPE), se inyectó código CSS personalizado mediante st.markdown, modificando la paleta de colores de los componentes (botones en rojo) y la tipografía.

Lógica de Persistencia Directa: El frontend se conectó directamente con la API de Airtable. Mediante el uso de st.session_state, se implementó una validación que confirma el éxito del envío y bloquea duplicados, asegurando que la experiencia del atleta sea fluida y sin errores técnicos visibles.

Panel del Inspector: Dashboard de Alto Rendimiento (1_Admin.py)

El panel de administración es una herramienta de ingeniería diseñada para la gestión masiva de expedientes y la visualización de resultados del motor RAG. Su construcción técnica destaca por:

Gestión de Estado de Sesión (Session State): A diferencia de la mayoría de aplicaciones Streamlit que se reinician en cada interacción, aquí se utilizó el objeto st.session_state para mantener la persistencia de la búsqueda. Esto permite que el inspector pueda navegar entre atletas y volver a los resultados de búsqueda sin perder la información procesada por el LLM.

Arquitectura de Visualización Paginada (3x3): El desafío técnico fue presentar 9 candidatos sin saturar la pantalla. Se desarrolló una lógica de paginación dinámica en Python que divide la lista de candidatos en subgrupos de 3. Mediante el cálculo de índices dinámicos (inicio = pag_actual * 3), el sistema renderiza columnas asíncronas (st.columns) que muestran:

- La silueta técnica de LEXI.
- La descripción médica experta recuperada de FAISS.
- El mapeo de deportes compatibles extraído del archivo mapa_deportes.json.

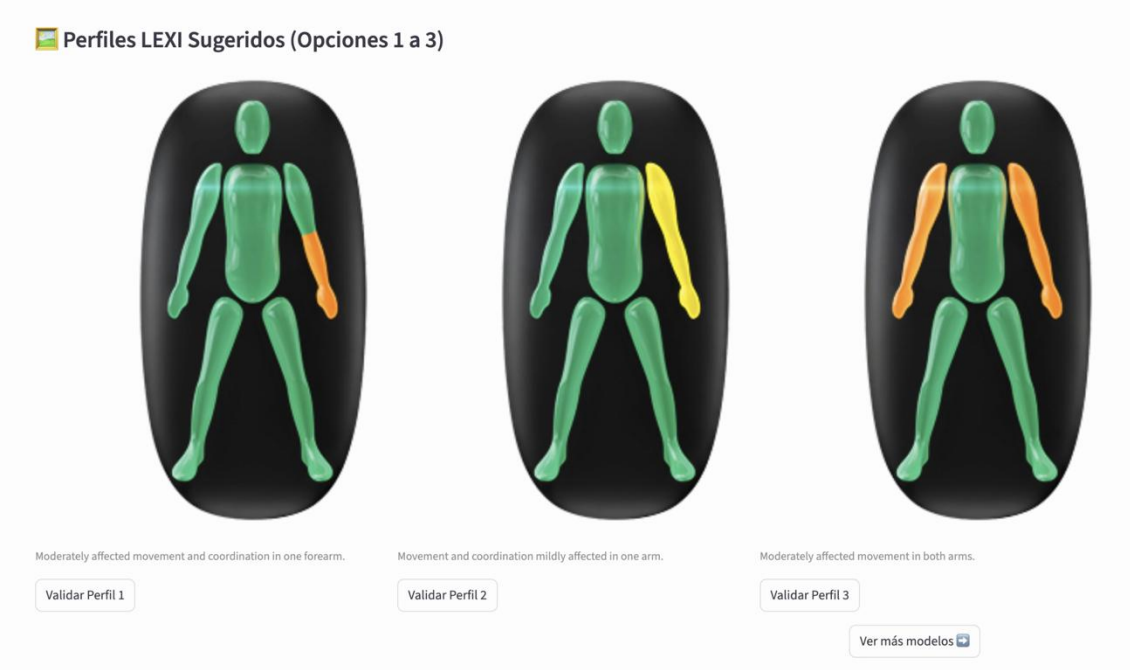

Optimización de Recursos con Caching: Se utilizó el decorador @st.cache_resource para cargar en memoria el índice vectorial FAISS y los diccionarios JSON. Esto garantiza que la navegación por el dashboard sea instantánea, eliminando tiempos de carga repetitivos durante la jornada de triaje del inspector.

Sincronización Cloud: La interfaz no solo lee datos, sino que permite la edición en tiempo real. Al validar un perfil, el sistema ejecuta un comando update sobre la API de Airtable, moviendo al atleta de categoría y registrando la decisión de la IA de forma permanente.

Flujo de Interacción UI-IA

El diseño permite que el inspector compare el relato subjetivo del atleta con las propuestas técnicas de LEXI. Esta disposición visual fue clave para facilitar el vínculo entre el lenguaje natural y la clasificación técnica, convirtiendo la interfaz en un puente de comunicación entre el usuario y la base de datos vectorial.

3.5. Testing and Improvements

Modelo LEXI.
El estado actual de ParaTalent Hub es el resultado de un ciclo de desarrollo iterativo basado en pruebas de estrés y validación de resultados. Durante la fase de testeo, se identificaron cuellos de botella críticos que comprometían la precisión del triaje, lo que llevó a la implementación de las siguientes mejoras de ingeniería:

Resolución del "Semantic Gap" Lingüístico

Durante las primeras pruebas de recuperación, detectamos que el sistema presentaba una tasa de error importante cuando el relato del atleta se introducía en español ya que no terminaba de mostrar imágenes tan parecidas a la descripción de la discapacidad proporcionada. Aunque los modelos de embeddings son multidimensionales, la distancia vectorial entre una descripción coloquial en español y un perfil médico técnico en inglés (estándar de LEXI) era demasiado elevada, lo que provocaba que la similitud de coseno devolviera resultados irrelevantes. Por ello, Implementamos la Traducción Técnica y Refinamiento Semántico previo a la consulta en FAISS. El sistema ahora traduce el relato al inglés médico especializado antes de vectorizarlo, alineando el input con el corpus de conocimiento y elevando la precisión de la recuperación a niveles óptimos

Implementación de Reglas estrictas para la Coherencia Clínica

Las pruebas demostraron que, en ocasiones, la búsqueda puramente semántica sugería perfiles que, aunque parecidos en texto, eran físicamente imposibles para el atleta. Un atleta con una discapacidad física en las piernas podía recibir sugerencias de categorías de "Discapacidad Visual" si su relato mencionaba términos que la IA confundía semánticamente. Para mejorarlo, introdujimos una capa de filtrado por reglas de negocio (Hard Rules) basada en los metadatos de los documentos. El sistema ahora cruza los "Medical Flags" del usuario con la categoría del documento recuperado; si hay una incongruencia clínica, el candidato se descarta antes de llegar al inspector, garantizando un flujo con cero errores de categoría base.

Mitigación de la Carga Cognitiva en la UI

En el lado del administrador, detectamos que la presentación de resultados era un punto crítico para el inspector del CPE. Mostrar solo 3 descripciones técnicas en una dificultaba la toma de decisiones en caso de que el modelo no eligiera la imagen optima. Por ello, decidimos incorporar 9 descripciones. Diseñamos el sistema de Paginación Dinámica en Streamlit. Mediante la gestión de estados de sesión, el inspector ahora procesa la información en bloques digeribles de tres candidatos. La implementación de la Visualización Paginada (3x3) no es solo estética; responde a una necesidad de validación experta. Al presentar los 9 mejores candidatos jerarquizados por el proceso de Reranking, el inspector puede validar la opción óptima en la primera página o explorar alternativas cercanas de forma estructurada, reduciendo el tiempo de decisión clínica.

Gracias a estas mejoras, ParaTalent Hub ha pasado de ser un prototipo de búsqueda a una herramienta lista para usar. La combinación de traducción técnica, optimización de contexto y filtrado lógico asegura que el Comité Paralímpico Español cuente con un sistema donde la Inteligencia Artificial actúa como un filtro de alta fidelidad, dejando la decisión final en manos del experto humano con la máxima confianza posible.

Prevención de Alucinaciones de Índice

Se ha incorporado una capa de validación de rango en la salida del modelo. El sistema verifica que los IDs devueltos por la IA existen dentro del espacio vectorial recuperado (k=15) antes de intentar renderizarlos. Esta medida de seguridad evita que posibles alucinaciones del modelo de lenguaje generen errores de índice en la interfaz de usuario, garantizando la estabilidad total de la plataforma en entornos de producción.

Modelos de Predicción.

Una vez hemos observado que los modelos se comportan de la misma manera separando por género que manteniéndolo mixto y que dependiendo del objetivo que queramos debemos escoger el RF o el MLP, debemos escoger entre usar el modelo de 4 o 2 clases.

Como se puede ver en las tablas 1, 2, 3 y 4, las métricas que se obtienen son mucho mejores en el caso de 2 clases objetivo, las que hemos denominado “élite” y “no élite”. Debido a esto y a que lo que queremos conseguir es saber quiénes de entre todos los aspirantes que tenemos están dotados de un rendimiento superior al resto; optamos por quedarnos con el RF y el MLP entrenados con dos clases objetivo y con los géneros mezclados.

4. Projected Impact

El presente proyecto aborda una problemática clave en los procesos de captación y clasificación del Comité Paralímpico Español (CPE): la gestión eficiente de un alto volumen de aspirantes con información heterogénea y, en muchos casos, no estructurada.

A través del desarrollo de dos enfoques complementarios:
- Un sistema basado en recuperación aumentada (LEXI)
- Un modelo predictivo entrenado sobre un dataset de potencial físico

Con el uso de esta herramienta se propone una solución orientada a mejorar la eficiencia, consistencia y escalabilidad del proceso de preclasificación y detección de talento.

4.1. Accomplishments and Benefits

Optimización del proceso de preclasificación

Uno de los principales logros del proyecto es la mejora del proceso de análisis inicial de aspirantes. Tradicionalmente, este proceso depende de la revisión manual de formularios, lo que implica una elevada carga operativa y una posible variabilidad en la interpretación de la información.

La herramienta LEXI introduce una capa de apoyo inteligente mediante el análisis automático de la descripción de la discapacidad proporcionada por el aspirante. A través de este sistema, se generan las cinco clasificaciones más cercanas según el estándar LEXI, que son presentadas en la interfaz de administración.

Este enfoque permite:
- Reducir significativamente el tiempo de análisis por aspirante
- Estandarizar la interpretación de descripciones no estructuradas
- Facilitar la toma de decisiones por parte del personal del CPE

Es importante destacar que el sistema no sustituye la decisión humana, sino que actúa como herramienta de apoyo, manteniendo el criterio experto como elemento central del proceso.

Mejora en la gestión de datos no estructurados

El proyecto aborda de forma directa uno de los principales retos identificados en el análisis exploratorio: la presencia de datos textuales heterogéneos, especialmente en la descripción de discapacidades.

El uso de técnicas basadas en embeddings y recuperación semántica permite transformar estas descripciones en información procesable, facilitando su comparación con clasificaciones existentes. Esto supone un avance significativo frente a enfoques tradicionales basados en reglas o categorizaciones rígidas.

Apoyo a la identificación de talento mediante modelos predictivos

De forma complementaria, el desarrollo del modelo de machine learning introduce una segunda capa de análisis orientada a la identificación de deportistas con potencial de élite.
Para ello, se han explorado distintos enfoques:

- Modelos basados en árboles de decisión (Random Forest), por su interpretabilidad y robustez
- Redes neuronales (Multi-Layer Perceptron), por su capacidad para capturar relaciones no lineales

Asimismo, se han considerado diferentes estrategias de modelado:

- Clasificación multiclase (A, B, C, D)
- Clasificación binaria (élite vs no élite)

Y diferentes segmentaciones del dataset:

- Modelos mixtos
- Modelos específicos por género

Este enfoque experimental permite identificar qué combinación ofrece mejores resultados en la detección de perfiles con mayor potencial, aportando una base sólida para futuras decisiones estratégicas en captación de talento.

Impacto global en el CPE

En conjunto, las soluciones desarrolladas permiten avanzar hacia un modelo más eficiente y escalable de gestión del talento deportivo:

- Mejora en la eficiencia operativa del proceso de preclasificación
- Reducción de la carga manual sobre el personal técnico
- Mayor consistencia en la evaluación de aspirantes
- Capacidad de análisis sobre grandes volúmenes de datos
- Base tecnológica para la digitalización de procesos internos

Este proyecto no solo responde a una necesidad actual, sino que sienta las bases para la evolución hacia sistemas más avanzados de apoyo a la decisión dentro del CPE.

4.2. Future Improvements

A pesar de los avances logrados, el proyecto presenta una serie de limitaciones y oportunidades de mejora que deben ser consideradas en futuras iteraciones.

Limitaciones actuales

Una de las principales limitaciones identificadas ha sido la disponibilidad de datos adecuados para el entrenamiento de modelos predictivos. El uso de un dataset externo, aunque útil para la experimentación, no garantiza una representación fiel de la realidad del CPE.

Asimismo, persisten desafíos relacionados con:

- La calidad y estructuración de los datos de entrada

- La ausencia de validación con datos reales del proceso de clasificación
- La necesidad de evaluación cuantitativa más exhaustiva de los modelos

Estas limitaciones refuerzan la necesidad de continuar desarrollando el proyecto en colaboración directa con el CPE.

Mejoras técnicas futuras

Entre las principales líneas de mejora técnica se encuentran:
- Entrenamiento de modelos con datos reales del CPE
- Mejora del procesamiento del lenguaje natural en descripciones de discapacidad
- Optimización de los modelos predictivos mediante técnicas de ajuste y validación
- Integración más estrecha entre el sistema LEXI y los modelos de predicción

Estas mejoras permitirían aumentar la precisión y fiabilidad de las soluciones desarrolladas.

Evolución hacia herramienta operativa

Una de las principales oportunidades del proyecto es su evolución hacia una herramienta plenamente integrada en los procesos del CPE.

En este sentido, se plantean posibles desarrollos como:
- Integración del sistema en el formulario real de captación
- Desarrollo de interfaces específicas para clasificadores
- Incorporación de mecanismos de retroalimentación para mejorar el sistema de forma continua

Líneas futuras de desarrollo

Más allá de la mejora del sistema actual, el proyecto abre la puerta a nuevas aplicaciones dentro del ámbito de la captación y retención del talento deportivo:

- Desarrollo de un sistema de recomendación de instalaciones deportivas adaptadas, mediante un mapa interactivo basado en el perfil del aspirante.
- Integración de los resultados del programa “Draft” del CPE como fuente de datos para mejorar los modelos predictivo.

Estas líneas futuras permiten ampliar el alcance del proyecto, posicionándolo como una base para un ecosistema digital más amplio dentro del CPE.

5. Team Member Review and Comment

NAME	REVIEW and COMMENT
Ignacio Jiménez Martín	Este proyecto ha demostrado que la unión de datos estructurados y el potencial de los Large Language Models (LLMs) permite resolver problemas complejos de clasificación médica que antes dependían exclusivamente de la memoria de expertos. El detector de élite añade una capa de valor competitiva que puede cambiar la forma en que el CPE capta nuevos talentos. Además, demuestra cómo la tecnología de última generación (RAG y Deep Learning) puede aplicarse a un nicho tan específico y valioso como el deporte paralímpico. La integración de múltiples fuentes de datos y plataformas (Web, Airtable, IA) ha resultado en una herramienta funcional y escalable.
Miguel Martín Rodrigo	Sin ningún tipo de duda, este ha sido un proyecto que ha supuesto un reto para todo el equipo. En primer lugar, identificamos una clara deficiencia en el proceso de reclutamiento, sobre la que tuvimos que buscar una solución. Para ello, nos pusimos en contacto con Manuel Martínez, nuestro enlace con el CPE, con el objetivo de comprender en profundidad el funcionamiento del sistema actual y poder plantear una solución que no implicara un cambio radical en su metodología de trabajo. A partir de este análisis, definimos una línea de trabajo que, apoyándonos en todo lo aprendido durante estos meses de formación, nos permitió diseñar e implementar una solución basada en modelos de inteligencia artificial como LLMs, MLP y Random Forest. Gracias a ello, potencialmente conseguimos mejorar significativamente la eficiencia del proceso, optimizando tareas clave y facilitando la toma de decisiones dentro del flujo de reclutamiento. Si hay algo que destacaría de este proyecto es la capacidad que hemos desarrollado para enfrentarnos a problemas reales utilizando herramientas tecnológicas avanzadas. Más allá del potencial que estas soluciones tienen a futuro, este proyecto nos ha permitido comprobar de primera mano su aplicabilidad en contextos reales y el valor que pueden aportar desde el primer momento. A nivel personal, destacaría especialmente el trabajo en equipo que hemos llevado a cabo, apoyándonos mutuamente para superar los distintos retos que han ido surgiendo a lo largo del proyecto. Asimismo, me gustaría mencionar a nuestro tutor, David, cuya orientación ha sido clave desde el inicio, guiándonos en cada fase y aportándonos los conocimientos necesarios para afrontar las dificultades y comprender en profundidad cada uno de los pasos realizados. Tanto la formación recibida durante estos meses como la realización de este proyecto junto a mi equipo han supuesto una experiencia muy enriquecedora, que me permite seguir avanzando con mayor preparación y confianza en mi desarrollo profesional.
Juan S. Flores Olivos	Este proyecto me permitió enfrentar uno de los principales retos en Inteligencia Artificial: la calidad de los datos. Trabajar con información real del CPE evidenció que el mayor desafío no es el modelo, sino la falta de estructura y consistencia en los datos disponibles. El proceso de limpieza, homogeneización y análisis exploratorio fue clave para comprender estas limitaciones y definir su uso adecuado. Aunque los datos no eran aptos para modelos predictivos, sí resultaron valiosos para entender el perfil de los aspirantes y validar el sistema RAG. Este proyecto refuerza la importancia de un enfoque integral en IA, donde la calidad de los datos, el análisis previo y la correcta definición del problema son tan relevantes como el propio modelo.

6. Instructor Review and Comment

CATEGORY	SCORE	REVIEW and COMMENT
IDEA	__/10	
APPLICATION	__/30	
RESULT	__/30	
PROJECT MANAGEMENT	__/10	
PRESENTATION & REPORT	__/20	
TOTAL	__/100	

7. Annexes

Toda la documentación y código del proyecto se encuentra en el siguiente repositorio de github: https://github.com/nachojimenez1/samsung_paratalenthub